慶應義塾大学 理工学部 情報工学科 自然言語処理 (2026/04/09)

01 - イントロダクション

情報工学科 准教授　高道 慎之介

Takamichi Laboratory
慶應義塾大学 高道研究室

本講義について

自己紹介

@forthshinji

名前

高道 慎之介 (たかみち しんのすけ)

現職

慶應義塾大学 准教授／東京大学 特任准教授

専門

音声工学，音声言語処理，機械学習，信号処理

受賞

IEEE SPS Young Author Best Paper Award
文部科学大臣表彰 若手科学者賞

この講義の目的

- **計算機を用いて言語を計算・理解する技術 (technology)** を理解する.
  - 言語を科学 (science) する内容は他講義に譲る
    - 小原先生：言語科学特論（大学院）
    - 小原先生・高道：自然言語処理特論（大学院）

- 大規模言語モデル (LLM) に係る数学・情報技術を理解する.

- 以上に付随して関連分野を理解する.
  - 翻訳、音声入力、情報検索、ヒューマンマシンインターフェース
  - 音声情報処理

自然言語処理とは

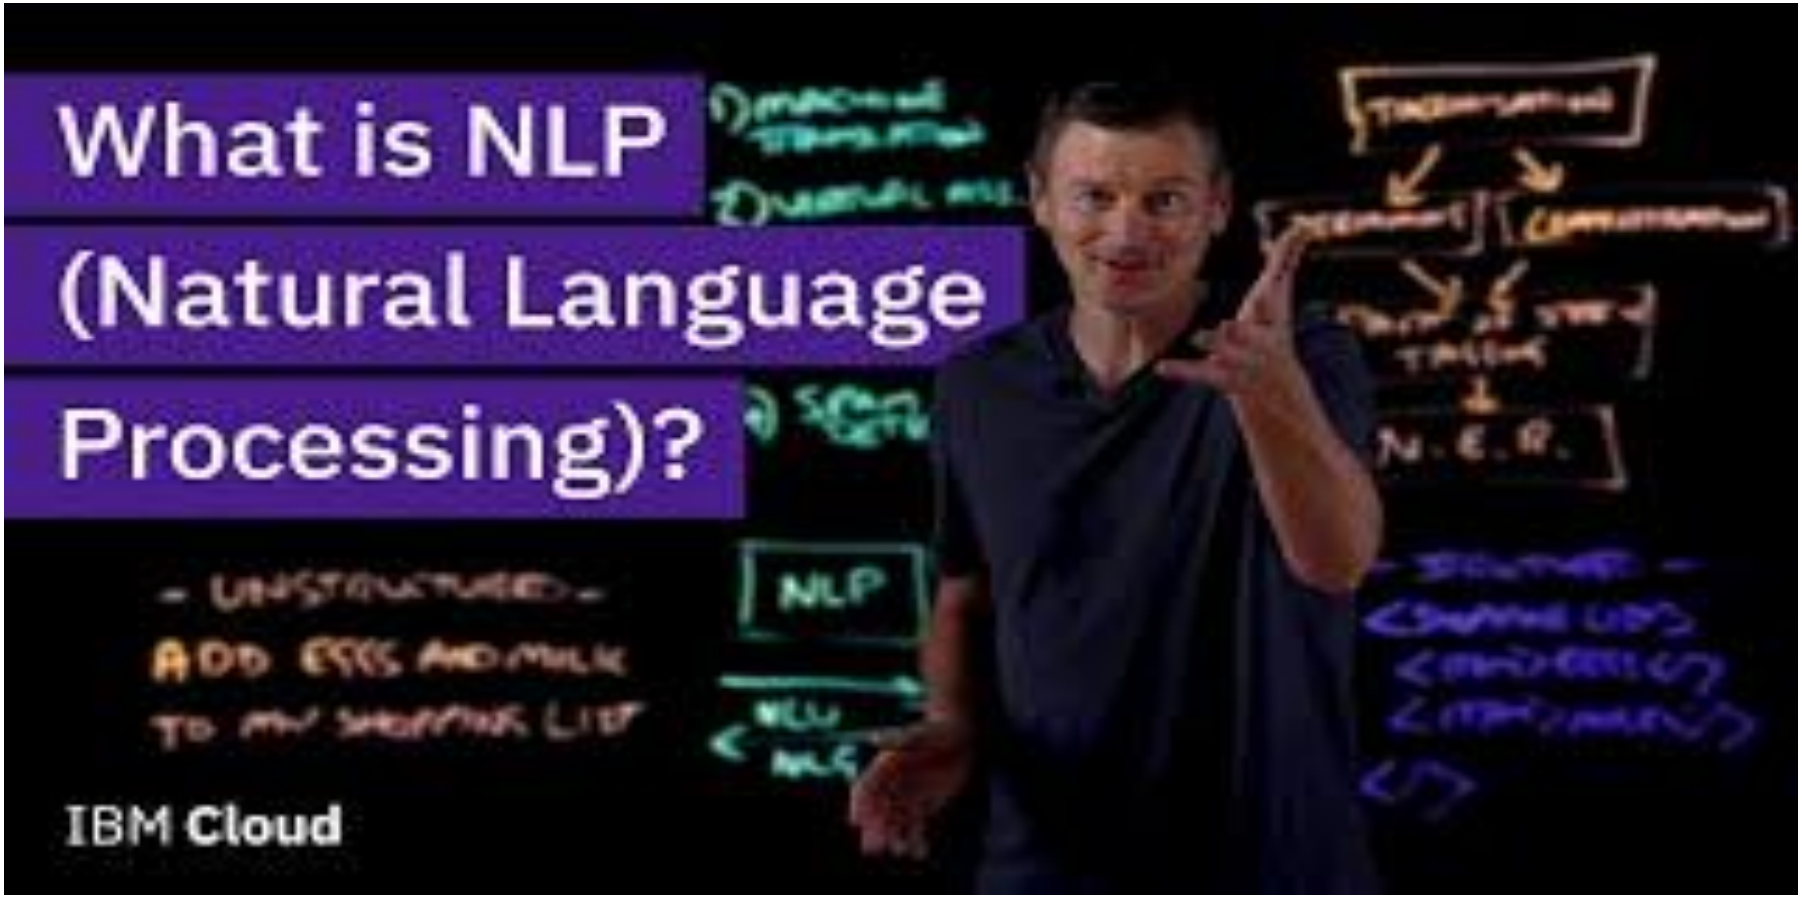

成績の付け方

- 内訳
  - 50 / 100 … 講義での演習
  - 50 / 100 … 期末試験

- 演習
  - 毎講義 (02回〜) の終わりに課題を出します．提出は K-LMS 上．
  - 締切は1週間後の前日 23:59．詳細は各講義の演習内容を参照．

- 期末試験 (筆記試験)
  - 演習の内容を理解していれば単位をとれるようにするつもり．
  - 本講義の内容が皆さんの人生に (いつか) 資すると思うなら，
    上の点数を目指すこと．

基盤モデル (大規模言語モデルなど) の使用

- 基盤モデルとは．
  - ChatGPT，Google notebookLM, etc.

- 活用は妨げない．
  - 利用した場合は使用の旨を明記し生成履歴を記載せよ．使用有無による加減点は無い．**ただし，使用したにも関わらず明記のないものは，当該点数を 0 点とする．**
  - 生成履歴を踏まえて，自分の言葉で回答せよ．

- **自分 (人間) を成長させるために，講義も基盤モデルも利用せよ．**
  - 生成履歴を残すことで，自分の理解の過程を反芻してほしい．
  - 成長を期末試験で問う (期末試験では基盤モデル使用は不可)．

必要な事前知識 (復習はします)

- 数学
  - 線形代数：ベクトル，行列，線形変換
  - 確率統計：離散変数の確率

- 機械学習
  - 教師あり学習： train/dev/test 分割，モデル学習
  - 深層学習：Feed-forward, バックプロパゲーション

- プログラミング
  - Python：主に課題で使用

講義予定

第XX回	日付	内容（順次変わっていくので予想）	
第01回	**2026/04/09**	**イントロダクション**	事前知識の確認
第02回	2026/04/16	自然言語処理のための機械学習に入門する	
第03回	2026/04/23	言語学に入門する	言語とは何だろう
第04回	2026/04/30	単語をベクトルで表現する	自然言語処理の基礎技術
第05回	2026/05/07	言語モデルで文章を統計的に扱う	
第06回	2026/05/14	系列にラベリングする	
第07回	2026/05/21	演習１	これまでの復習
第08回	2026/05/28	Transformer を理解する	大規模言語モデル時代の技術
第09回	2026/06/04	言語モデルを事前学習する	
第10回	2026/06/11	言語モデルを転移学習する	
第11回	2026/06/18	言語を生成 (デコーディング) する	
第12回	2026/06/25	言語やラベルを評価する	
第13回	2026/07/02	自然言語処理から音声言語処理へ	おまけ
第14回	2026/07/09	演習２	これまでの復習
期末試験	2026/07/XX	(日程は後日アナウンス)	

講義資料について

- https://github.com/takamichi-lab/nlp-lecture-keio
- K-LMS にも記載済み
- 講義資料＆演習課題はすべてこのページにアップロード予定.
- 基盤モデルに入力しても構わない.

今日の目的：
自然言語＆自然言語処理とは何かを知る

自然言語 (natural language) とは？

自然言語とは

- **社会において自然に発生して用いられている言語**
  - 主に人間同士で意志疎通を行うことを目的として、
    人間が読み・書き・聞き・喋り・思考するための言語
  - 例：日本語、英語、ドイツ語、フランス語、…
    (本講義では扱わないが日本手話，英語手話，...)

- 対義語は 人工言語 (artificial language)
  - エスペラントなど人工的につくられた言語
  - 形式言語（記号論理学やコンピュータープログラミングのためにつくられた記号や式によって作られた人工言語）
  - 本講義では人工言語を扱わず，言語＝自然言語とする．

クレオール言語 (宜蘭クレオール)

アフリカにあるクリック言語

日本の諸方言 (動画は熊本県天草地方)

自然言語は社会のあり方を反映する

自然言語処理 (natural language processing) とは？

自然言語には音声や手話も含まれるが，歴史的に NLP は文字言語に対する処理を指すことが多い．本講義もそれに倣う．

自然言語処理とは

- 計算機を用いて自然言語を扱う学問あるいは技術である.
- 人間と計算機のコミュニケーションに資する技術である.
- 人間同士のコミュニケーションに資する技術である.
- 言語そのものを理解する手段である.

自然言語処理とは

- 計算機を用いて自然言語を扱う学問あるいは技術である．
- **人間と計算機のコミュニケーションに資する技術である．**
- **人間同士のコミュニケーションに資する技術である．**
- 言語そのものを理解する手段である．

質問応答 (questioning and answering)

✓

慶応義塾大学の現在の学長は誰ですか？

慶應義塾大学（慶應義塾）の現在の学長（塾長）は、

👉 **伊藤 公平（いとう こうへい）** です。

✗

神奈川県川崎市川崎区追分町444-11 にある施設を教えて
(存在しない住所)

結論からいうと、
「神奈川県川崎市川崎区追分町444-11」という住所にピンポイントで特定できる有名施設（公共施設・商業施設など）は確認できず、一般的な住宅・マンション系の建物があるエリアです。

対話 (dialogue)

映画の超かぐや姫みた？

まだ観てないんだよね。どうだった？面白かった？

タイトル的にちょっと気になるけど、「かぐや姫の物語」とは別物っぽいよね。もしよかったら、どんな感じの映画か教えてくれたら嬉しい。

なんというかアレだね，４回は見たほうがいいよ

それはもう「1回じゃ全然足りないタイプ」のやつだね笑

4回ってことは、
1回目：理解が追いつかない
2回目：構造が見えてくる
3回目：細部でゾクっとする
4回目：完全にハマる

みたいな感じ？

機械翻訳 (machine translation)

Captain Eli @TheCaptainEli · 2025年8月15日

翻訳を表示

פוסט זה כתוב בעברית.
אם אתה קורא את זה באנגלית אתה יכול להודות לאילון מאסק והצוות המדהים שלו.
זה פשוט כיף ונוח שאני לא צריך להתאמץ יותר ולעבוד על תרגום.
ממש תודה.

בנוסף רציתי לומר לך אילון, אם אתה קורא את זה..
התגובות ממש ממש ממש חיוביות, אנשים ציפו לזה.
זה מחבר בינינו האנשים ממש.

352 422 3,385 98万

Elon Musk
@elonmusk

購入する

翻訳を表示

Grok auto translate will allow posts in all languages to be seen by the world!

https://x.com/elonmusk/status/1956086133403832412

Captain Eli @TheCaptainEli · 2025年8月15日

ヘブライ語からの翻訳 原文を表示

この投稿はヘブライ語で書かれています。
英語でこれを読んでいるなら、イーロン・マスクと彼の素晴らしいチームに感謝してください。
これがただ楽しいし、便利で、もう翻訳のために努力したり作業したりする必要がないんです。
本当にありがとう。

また、イーロン、あなたがこれを読んでいるなら言いたかったんだけど..
反応が本当に本当に本当に本当にポジティブで、人々はこれを待っていました。
これが私たち人々を本当に繋げてくれます。

352 422 3,385 98万

Elon Musk
@elonmusk

購入する

英語からの翻訳 原文を表示

Grokの自動翻訳により、すべての言語の投稿が世界中で見られるようになります！

自然言語処理とは

- 計算機を用いて自然言語を扱う学問あるいは技術である．
- 人間と計算機のコミュニケーションに資する技術である．
- 人間同士のコミュニケーションに資する技術である．
- **言語そのものを理解する手段である．**

人間の言語能力を数理的に解明しよう

- 「お昼どこかに食べに行かない？」→「XXはどう？」
  - 人間：可能だが脳による計算は**観測できない**
    - 社会的関係，好物，時間制約，昨日食べたもの，etc.
  - 計算機：同様に可能で，その計算過程は**観測できる**
    - **→ 人間と計算機を対比させて，人間の知能の仕組みを知る**

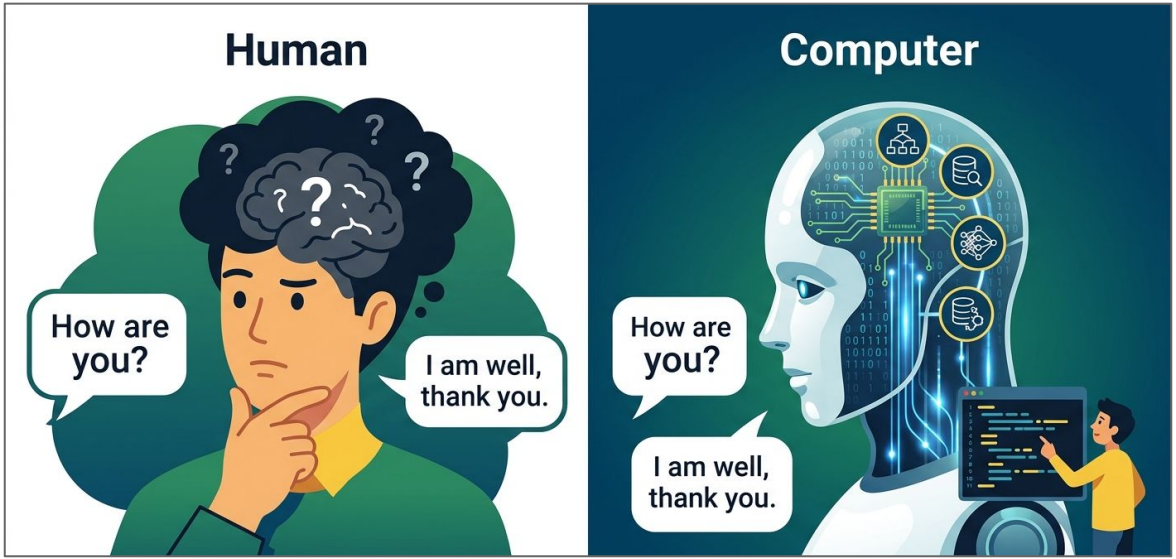

時代に応じて単語の意味はどう変化してきたか？

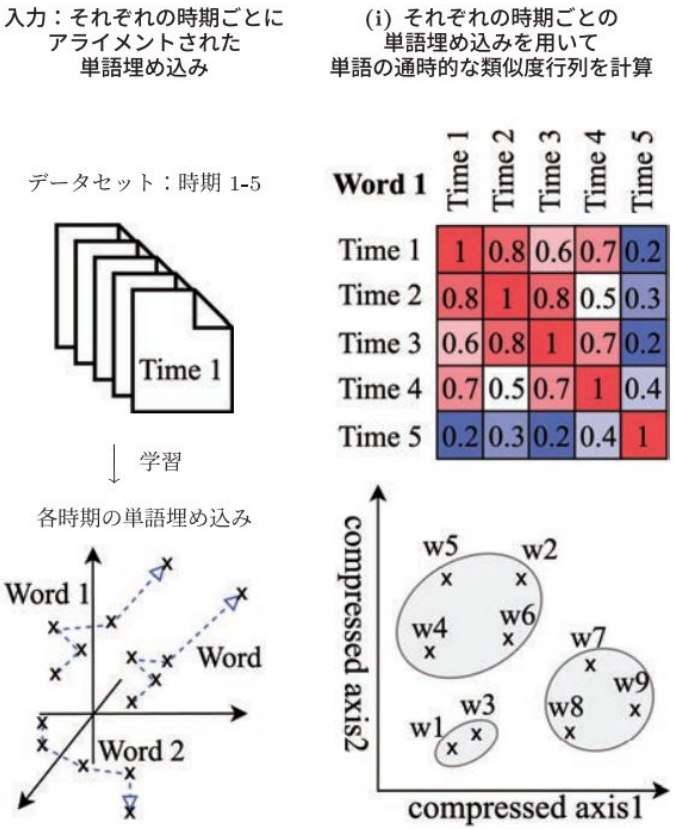

録音機器の登場前後で “record” の語義が変化

$\mathcal{T}_1$	$\mathcal{T}_2$	共起単語	語義の解釈
1830–1910	1920–2010	tradition, miracle, monument, memorial, chapter, page, manuscript, contemporary, deed, event	出来事や物事を保存
1920–2010	1830–1910	attendance, set, track, sale, music, break, win, league, season, company	音を再生するメディア スポーツの記録

表 4 COHA から学習された単語「record」に対する領域 1（1830–1910 年）と領域 2（1920–2010 年）の間の PPMI 差分 ($\mathcal{N}_k^{(\mathcal{T}_2 \to \mathcal{T}_1)}$) に基づく上位 10 語とその語義の解釈．$\mathcal{T}_1$ は対象時間領域を表す．

https://www.jstage.jst.go.jp/article/jnlp/32/4/32_1189/_pdf/-char/ja

言語の有契性 (言語と意味には関係がある) はどう違う？

A. ゴルゴドンは　**B. コルコトン**は
怖い怪獣だ　vs　怖い怪獣だ

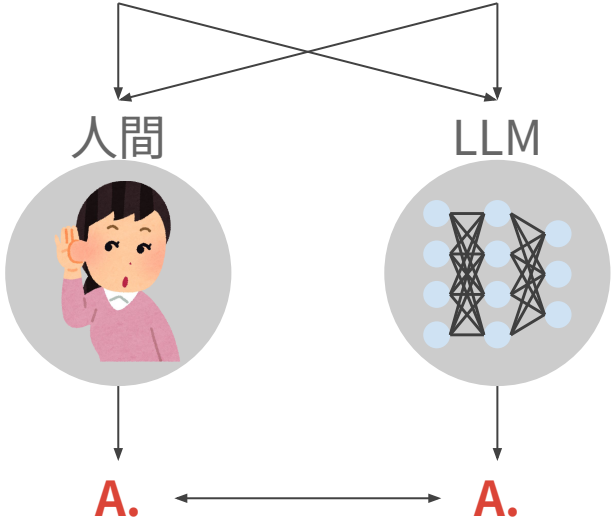

どれくらいの文対で一致？

表 2　学習済み言語モデルの平均スコアと相関
※ 0.3 以下を **赤字**，0.7 以上を **青字** で示している．

	Mean score	Human	Pythia-1B	Qwen2.5-3B	Llama3.2-3B	Llama3.1-8B
Human	0.605	1.000				
Pythia-1B	0.550	**0.145**	1.000			
Qwen2.5-3B	0.542	**0.247**	**0.923**	1.000		
Llama3.2-3B	0.551	**0.109**	**0.866**	**0.892**	1.000	
Llama3.1-8B	0.553	**−0.236**	**0.749**	**0.775**	**0.814**	1.000

種類の違うLLM同士は似た回答をするが，
LLMと人間はそうでは無いみたい

稲垣 他，“大規模言語モデルの音象徴ベンチマーク”, 言語処理学会, 2026.

計算機技術としての自然言語処理

自然言語処理システム＝自然言語入出力に対する関数

X	$f(\cdot)$	Y
テキスト	言語モデリング	テキストの続き
テキスト	機械翻訳	他言語テキスト
テキスト	テキスト分類	ラベル
テキスト	言語分析	言語構造
画像	画像キャプショニング	テキスト
音声	音声認識	テキスト

システムを実現する方法は 3 つある

- **規則**：手動設定した規則に基づく

```python
def dialogue_response(x: str) -> str:
    if x == "Hello":
        return "Hi there!"
    else:
        return "Sorry, I don't understand that."
```

- **プロンプト**：言語モデルにプロンプトを与える

x = "Hello" のときは "Hi there!" と返答し，
x がそれ以外の時は "Sorry, I don't understand that." と返答しなさい．

x = "Good morning"

→ Sorry, I don't understand that.

- **学習**：(X, Y) の対データを用いて機械学習モデルを学習する

“Hello”	“Hi there!”
“How are you?”	“I’m doing well!”
“Goodbye”	“See you later!”

→ 学習

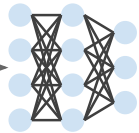

システム構築に必要なデータ

学習データ　検証データ　評価データ

- 規則・プロンプト
  - データ無しでも動作する．ただし性能の保証はない．
  - 少量の入力 X のデータがあれば，入力に対するチェックができる．
  - 少量の入出力対 (X, Y) があれば，厳格なルールや例示ができる．
    - → **検証データセット**

- 学習
  - さらなる**学習データセット**が必要．学習データは多いほど良い．
  - 学習データ量の対数に性能が比例する傾向．

規則に基づく予測

- **特徴抽出 (feature extraction)**
  - 意味のある特徴を入力テキストから抽出すること
  - $h = f(x)$
- **スコア計算 (score calculation)**
  - 特徴に基づいて，出力候補とそのスコアを計算すること
  - $s = g(h)$
- **決定 (decision)**
  - 出力候補のうちから 1 つを決定すること
  - $y = d(s)$

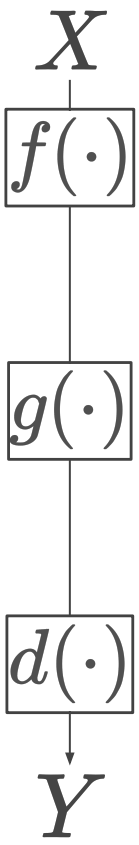

規則に基づくシステムを作ってみよう

https://github.com/takamichi-lab/nlp-lecture-keio/tree/main/2026/codes/01

- 方法１：ローカルに git clone して実行
  - git clone https://github.com/takamichi-lab/nlp-lecture-keio
  - cd 2026/codes/01

- 方法２：Google colab 上で実行
  - ファイル > ノートブックを開く > GitHub で URL を入力
  - 01-rule-based_classifier.ipynb を選択
  - 別途，sentiment_test.txt をアップロード

規則だけでは補えないことがある

```
positive_words = ["最高", "素晴らしい", "良い", "好き", "楽しい", "幸せ"]
negative_words = ["最低", "最悪", "悪い", "嫌い", "悲しい", "怖い", "難しい"]
```

- 低頻度語・未知語・新語はどうする？活用形は？否定は？他言語は？
  - 現れるたびに単語リストに追加する？単語の原型だけ扱う？否定も規則？

```
feature_weights = {"positive": 1.0, "negative": -1.0}
```

- 重みはこれでいいの？
  - 一回一回手動で調整する？

→ 特徴抽出・スコア計算・決定を機械学習に展開しよう！

機械学習に基づく予測

- **特徴抽出 (feature extraction)**
  - 意味のある特徴を入力テキストから抽出すること
  - $h = f(x)$ **→ 単語埋め込み (第04回) など**

- **スコア計算 (score calculation)**
  - 特徴に基づいて，出力候補とそのスコアを計算すること
  - $s = g(h)$ **→ 言語モデル (第09回)**

- **決定 (decision)**
  - 出力候補のうちから１つを決定すること
  - $y = d(s)$ **→ 言語モデルのデコーディング (第11回)**

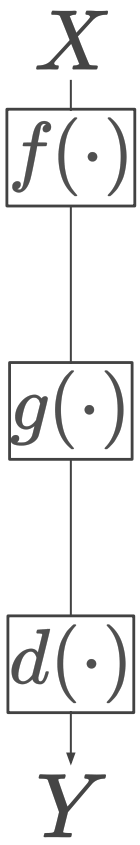

おまけ：プロンプトベースも同様に考えることができる

x = "Hello" のときは "Hi there!" と返答し，
x がそれ以外の時は "Sorry, I don't understand that." と返答しなさい．

x = "Good morning"

プロンプトによって，特徴量とスコア計算を変化させている

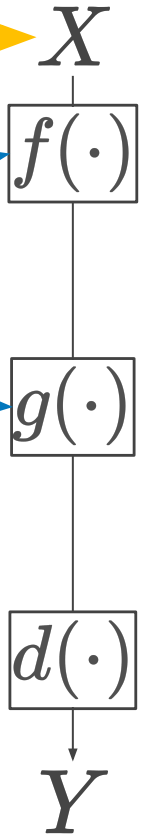

Sorry, I don't understand that.

まとめ (今回は演習なし)

まとめ

- 本講義について
- 自然言語とは？
- 自然言語処理とは？
- 計算機技術としての自然言語処理