慶應義塾大学 理工学部 情報工学科 自然言語処理 (2026/04/16)

02 - 自然言語処理のための機械学習に入門する

情報工学科 准教授　高道 慎之介

Takamichi Laboratory
慶應義塾大学 高道研究室

講義予定

第XX回	日付	内容（順次変わっていくので予想）	
第01回	2026/04/09	イントロダクション	事前知識の確認
第02回	**2026/04/16**	**自然言語処理のための機械学習に入門する**	
第03回	2026/04/23	言語学に入門する	言語とは何だろう
第04回	2026/04/30	単語をベクトルで表現する	自然言語処理の基礎技術
第05回	2026/05/07	言語モデルで文章を統計的に扱う	
第06回	2026/05/14	系列にラベリングする	
第07回	2026/05/21	演習１	これまでの復習
第08回	2026/05/28	Transformer を理解する	大規模言語モデル時代の技術
第09回	**2026/06/11**	言語モデルを事前学習する	
第10回	**2026/06/18**	言語モデルを転移学習する	
第11回	**2026/06/25** 変更	言語を生成 (デコーディング) する	
第12回	**2026/07/02**	言語やラベルを評価する	
第13回	**2026/07/09**	自然言語処理から音声言語処理へ	おまけ
第14回	**2026/07/16**	演習２	これまでの復習
期末試験	2026/07/XX	(日程は後日アナウンス)	

今日の目的：
線形代数・確率統計・微分積分を復習する

線形代数・確率統計・微分積分を復習する意義

慶應義塾大学 理工学部 情報工学科について短く教えてください.

慶應義塾大学 理工学部 情報工学科（Department of Information and Computer Science）は、最先端のコンピュータ技術から、それらを社会に役立てるための知能システムまでを幅広くカバーする ？？？ 学科？コース？

- LLM のような言語モデルは**確率**を表現している.
- 言語モデルはニューラルネットワークで構成されることが多い.
  - ニューラルネットワークは**線形代数**に基づいている.
  - ニューラルネットワークは**微分**を用いて学習される.

復習：確率

Do not edit
How to change the design

Join at slido.com
#4159924

Presenting with animations, GIFs or speaker notes? Enable our Chrome extension

slido

どこまで理解している？

Do not edit
How to change the design

Presenting with animations, GIFs or speaker notes? Enable our Chrome extension

slido

確率

- Q. 目を瞑って箱からボールを 1 つ取り出す行為を 10 回繰り返した．とったボールは毎回もとに戻す．赤い箱を 4 回，青い箱を 6 回選んだとき，各箱を選ぶ確率を求めよ．

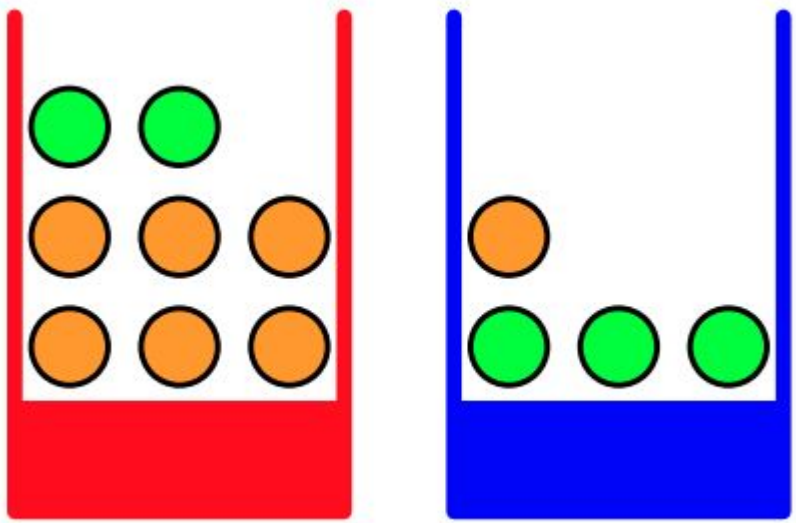

$$P(x = \text{赤い箱}) = \frac{4}{10}$$

$$P(x = \text{青い箱}) = \frac{6}{10}$$

規格化されているので総和が 1
(連続確率変数の場合は積分が 1)

(離散) 確率変数

常に非負

https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf

条件付き確率

- Q. 目を瞑って箱からボールを１つ取り出した．選んだ箱が青い箱だったとき，オレンジのボールを選ぶ確率を求めよ．

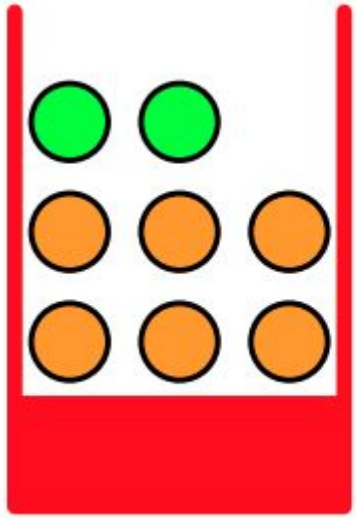

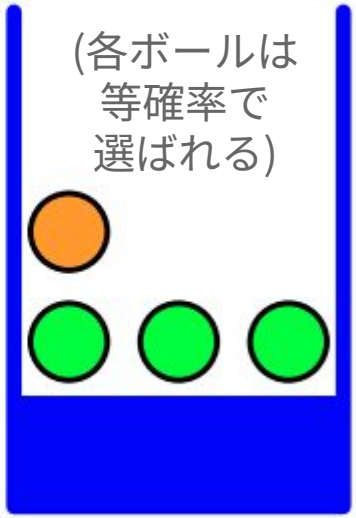

条件付き確率

$$P(y = \text{オレンジ} \mid \underbrace{x = \text{赤い箱}}_{\text{すでに起こった事象（＝条件）}}) = \frac{1}{4}$$

同時確率と連鎖律

- Q. 目を瞑って箱からボールを１つ取り出した．選んだ箱が赤い箱であり，かつ，オレンジのボールを選ぶ確率を求めよ．

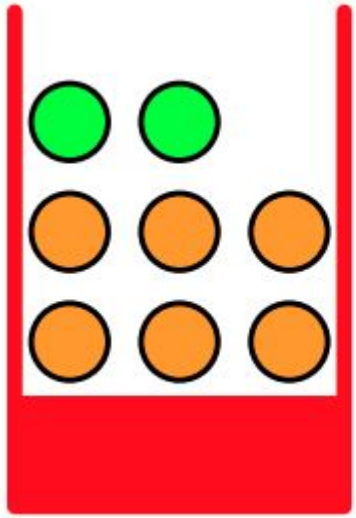

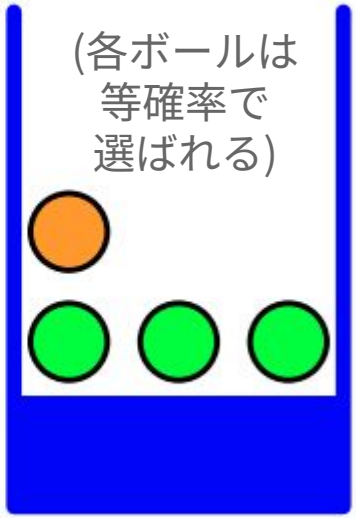

同時確率

$$P(y = \text{オレンジ}, x = \text{赤い箱})$$

$$= P(y = \text{オレンジ} \mid x = \text{赤い箱})P(x = \text{赤い箱})$$

x かつ y である確率は，x である確率と，
x であった下で y が起こる確率の積．

単語列で考えてみよう

私 / **は** / リンゴ / を / 食べる
彼 / **は** / バナナ / が / 好き / だ
私 / **は** / 公園 / に / 行く
リンゴ / が / 落ちる
私 / **は** / 赤い / リンゴ / を / 買う
空 / **は** / 青い
私 / **は** / 彼 / と / リンゴ / を / 分けた
彼女 / **は** / メロン / を / 食べる
私 / **は** / リンゴ / が / 大好き / だ
犬 / が / 走って / いる

50 単語の文章 (“/” は単語境界)

“私 は” の連続 2 単語の出現確率は？

$$P(\text{私}, \text{は}) = \underbrace{P(\text{は}|\text{私})}_{\text{“私” の後に “は” が出現する確率}}\underbrace{P(\text{私})}_{\text{“私” の出現確率}}$$

$$P(\text{私}) = \frac{5}{50}$$ (50 単語のうち 5 回出現)

$$P(\text{は}|\text{私}) = \frac{5}{5}$$ (“私” に後続する 5 単語のうち 5 回出現)

連続 3 単語以上にも拡張可能

$$P(\text{私}, \text{は}, \text{彼}) = P(\text{彼}|\text{は}, \text{私})P(\text{は}|\text{私})P(\text{私})$$

復習：線形代数

どこまで理解している？

Do not edit
How to change the design

Presenting with animations, GIFs or speaker notes? Enable our Chrome extension

slido

スカラ・ベクトル・行列，集合

表記	数	図示	表記ルール
a, A	スカラ		イタリック
$\boldsymbol{a}$	ベクトル	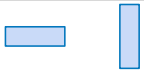	イタリック，ボールド，原則小文字
$\boldsymbol{A}$	行列		イタリック，ボールド，大文字

表記	意味	例
$\boldsymbol{A}^\top$	転置	$\boldsymbol{B} = \boldsymbol{A}^\top$ $^\top$ $\boldsymbol{b} = \boldsymbol{a}^\top$ $^\top$

表記	意味	言い換えると
$\mathbb{N}$	自然数	$0, 1, \ldots$
$\mathbb{Z}$	整数	$\ldots, -1, 0, 1, \ldots$
$\mathbb{R}$	実数	$(-\infty, \infty)$
$\mathbb{C}$	複素数	$a + jb$ or $r\exp(j\theta)$ with $a, b, r, \theta \in \mathbb{R}$

ベクトル・行列の和・積

ベクトルの和 (＝要素和)

$$\boldsymbol{a}+\boldsymbol{b}=\begin{bmatrix}a_1\\a_2\\\vdots\\a_n\end{bmatrix}+\begin{bmatrix}b_1\\b_2\\\vdots\\b_n\end{bmatrix}=\begin{bmatrix}a_1+b_1\\a_2+b_2\\\vdots\\a_n+b_n\end{bmatrix}$$

行列の和 (＝要素和)

$$\boldsymbol{A}+\boldsymbol{B}=\begin{bmatrix}a_{11}&\cdots&a_{1n}\\a_{21}&\cdots&a_{2n}\\\vdots&\ddots&\vdots\\a_{m1}&\cdots&a_{mn}\end{bmatrix}+\begin{bmatrix}b_{11}&\cdots&b_{1n}\\b_{21}&\cdots&b_{2n}\\\vdots&\ddots&\vdots\\b_{m1}&\cdots&b_{mn}\end{bmatrix}=\begin{bmatrix}a_{11}+b_{11}&\cdots&a_{1n}+b_{1n}\\a_{21}+b_{21}&\cdots&a_{2n}+b_{2n}\\\vdots&\ddots&\vdots\\a_{m1}+b_{m1}&\cdots&a_{mn}+b_{mn}\end{bmatrix}$$

行列の積

$$\boldsymbol{a}^\top\boldsymbol{b}=a_1b_1+a_2b_2+\cdots+a_nb_n$$

$$=\sum_{i=1}^{n}a_ib_i$$

(アダマール積も覚えておくと便利)

行列の積

$$c_{ij}=\sum_{k=1}^{n}a_{ik}b_{kj}$$

$$\begin{bmatrix}a_{11}&\cdots&a_{1n}\\\vdots&\ddots&\vdots\\a_{i1}&\cdots&a_{in}\\\vdots&\ddots&\vdots\\a_{m1}&\cdots&a_{mn}\end{bmatrix}\begin{bmatrix}b_{11}&\cdots&b_{1j}&\cdots&b_{1p}\\\vdots&\ddots&\vdots&\ddots&\vdots\\b_{n1}&\cdots&b_{nj}&\cdots&b_{np}\end{bmatrix}=\begin{bmatrix}c_{11}&\cdots&c_{1p}\\\vdots&c_{ij}&\vdots\\c_{m1}&\cdots&c_{mp}\end{bmatrix}$$

m n　　n p　　m p

線形変換 $\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x}$ とアフィン変換

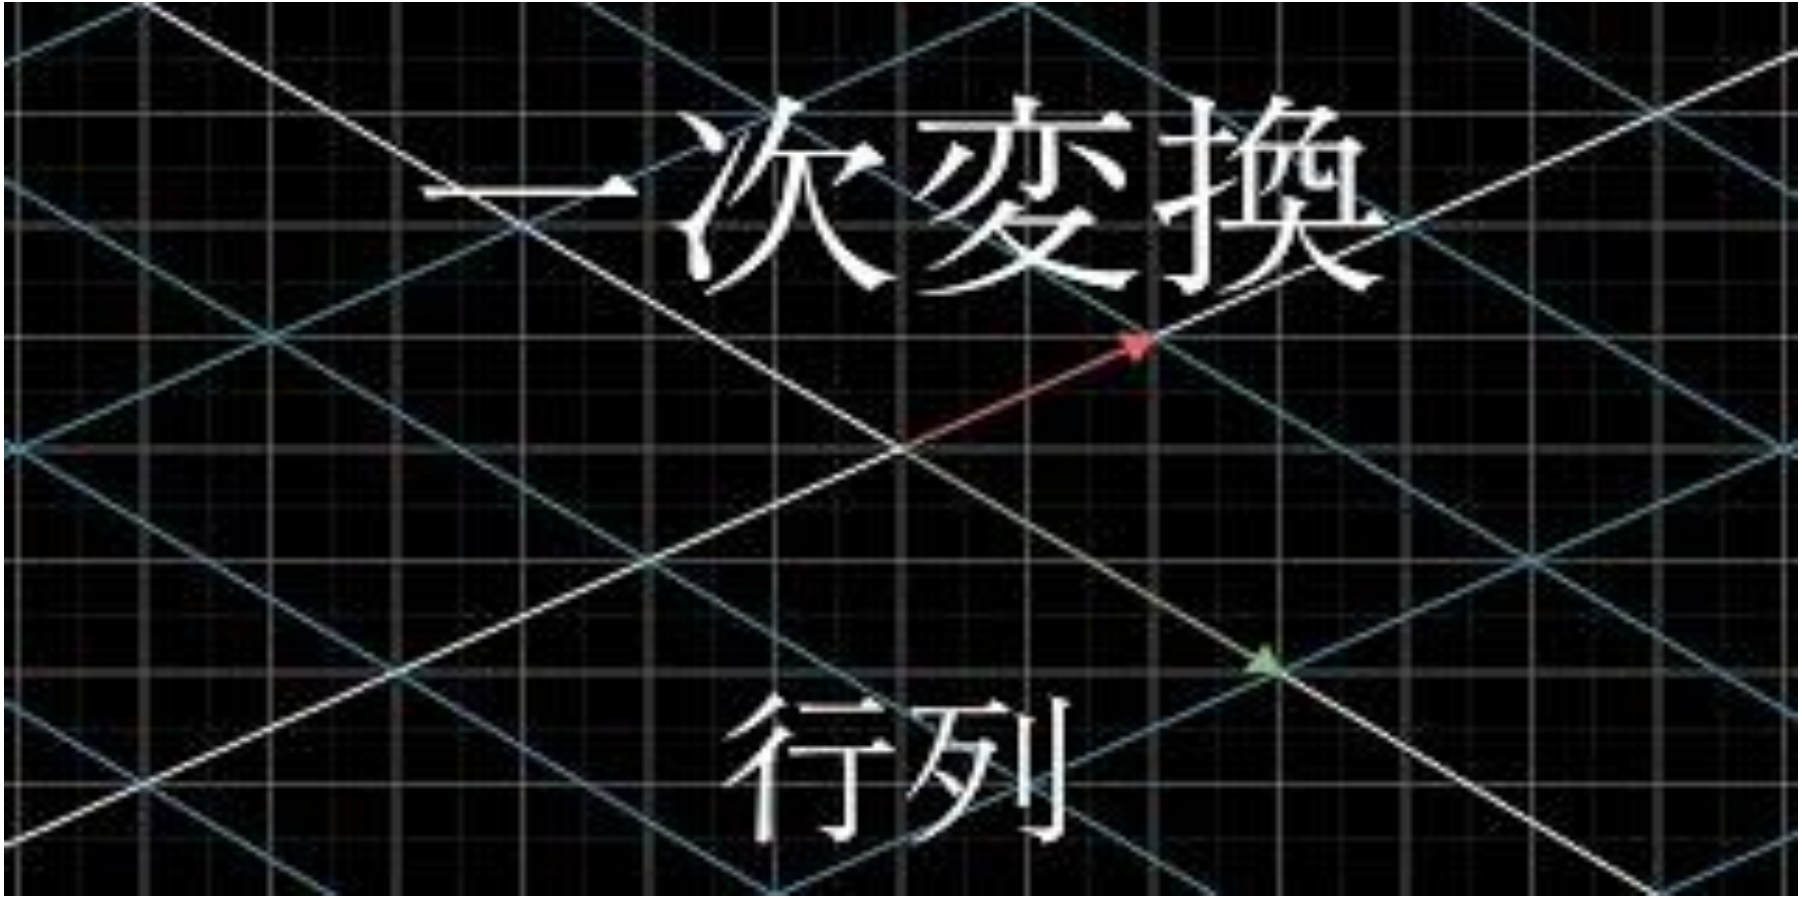

線形変換 $\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x}$ とアフィン変換

- 線形変換で回転・拡大縮小・せん断を表現できる

- アフィン変換になると，さらに平行移動が可能

$$\boldsymbol{y} = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b} \xrightarrow{\text{等価}} \boldsymbol{y} = \begin{bmatrix} \boldsymbol{A} & \boldsymbol{b} \end{bmatrix} \begin{bmatrix} \boldsymbol{x} \\ 1 \end{bmatrix}$$

復習：微分

どこまで理解している？

Do not edit
How to change the design

Presenting with animations, GIFs or speaker notes? Enable our Chrome extension

slido

関数の微分

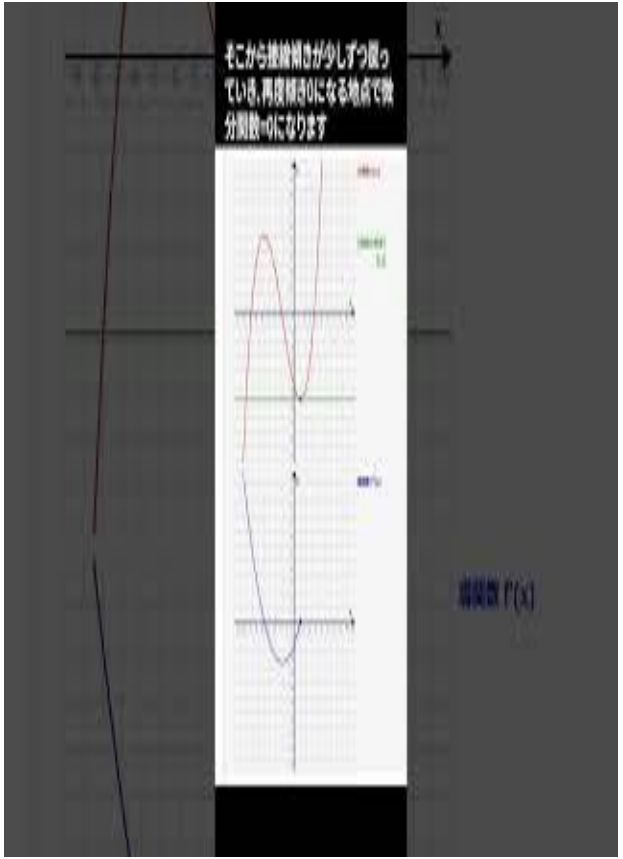

- 微分：変数の微小増分に対する関数の増分
- 変数と関数の種類に基づいて 3 種類を考慮
  - **スカラ**変数をとる**スカラ**値関数
  - **ベクトル**変数をとる**スカラ**値関数
    - ベクトル変数 = 多変数
  - **ベクトル**変数をとる**ベクトル**値関数
- 後述するニューラルネットワークで使用

スカラを引数にとるスカラ値関数

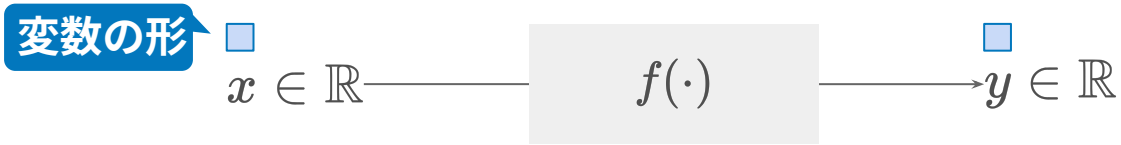

- 関数の例と微分を考える

- 例１：$f(x) = x^2$
  - その微分：$f'(x) = 2x$ 接線の傾き
  - x > 0 で $f'(x) > 0$ (右に向かって増)，x = 0 で $f'(x) = 0$ (最小値)

- 例２：$f(x) = \sin(x)$
  - その微分：$f'(x) = \cos(x)$
  - 変化率が周期的に変化．極小値・極大値が周期的に出現．

例えば勾配法（最急降下法など）に使う

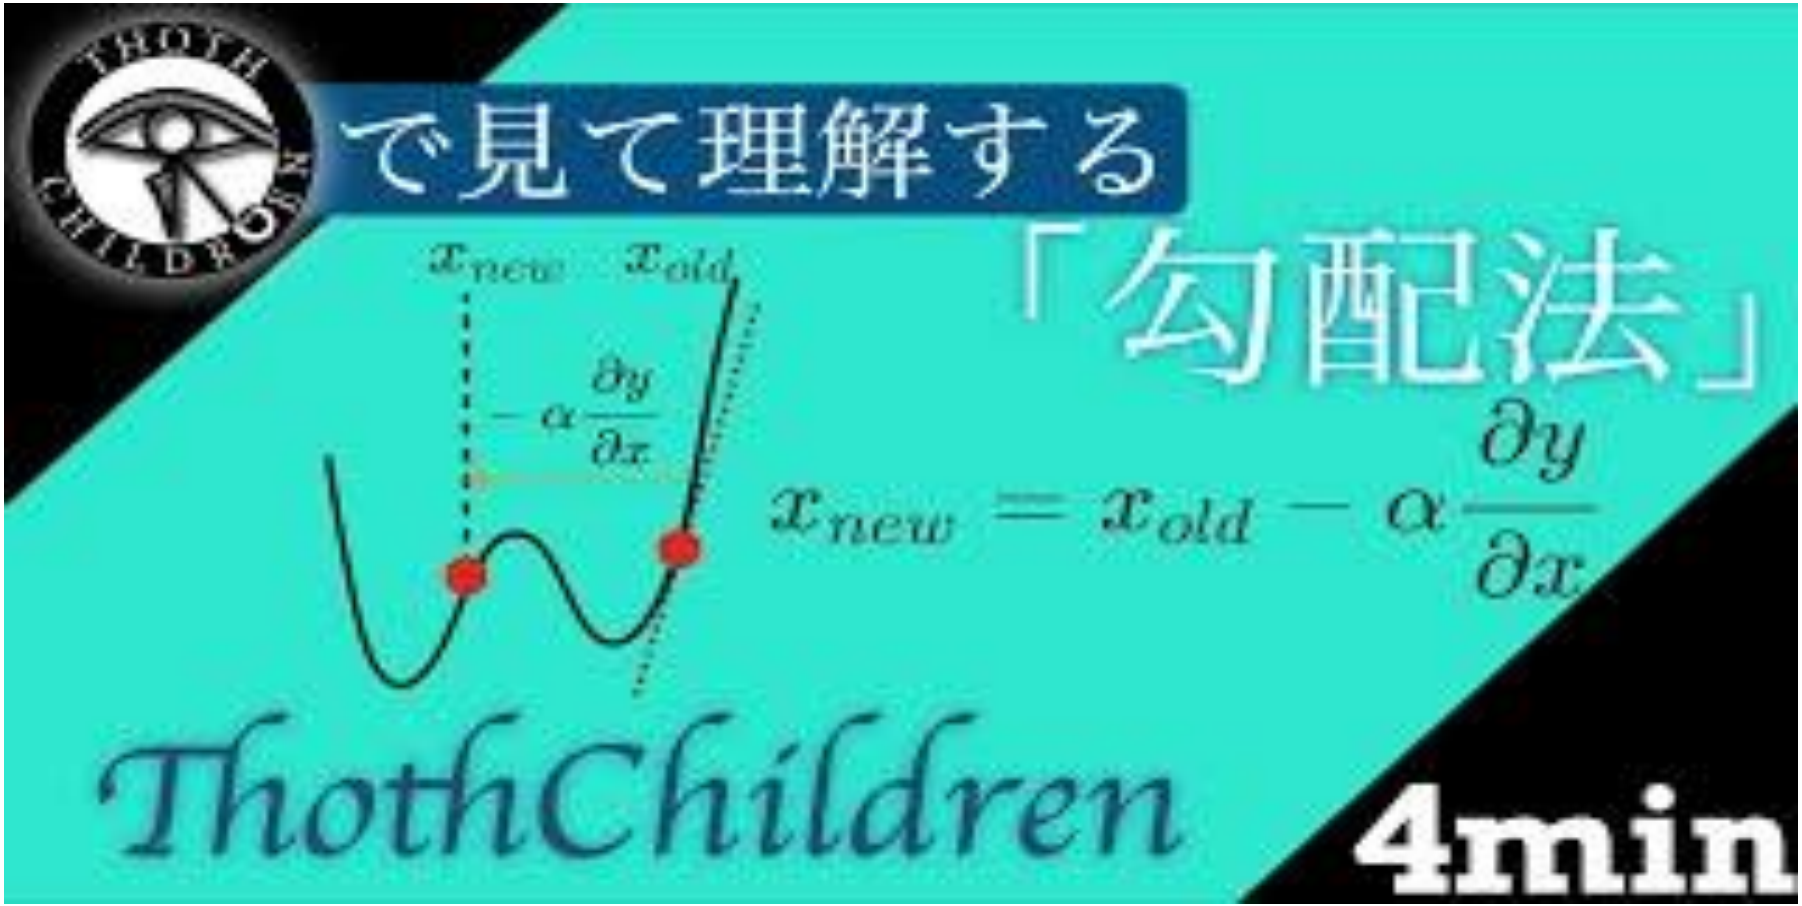

ベクトルを引数にとるスカラ値関数

基本的に列ベクトル

$$\boldsymbol{x} \in \mathbb{R}^N \longrightarrow \boxed{f(\cdot)} \longrightarrow \boldsymbol{y} \in \mathbb{R}$$

- 関数の例を考える
- 例：$f(\boldsymbol{x}) = \boldsymbol{a}^\top \boldsymbol{x}$
  - 書き換えると $f(\boldsymbol{x}) = \sum_i a_i x_i$
  - この(偏)微分は？

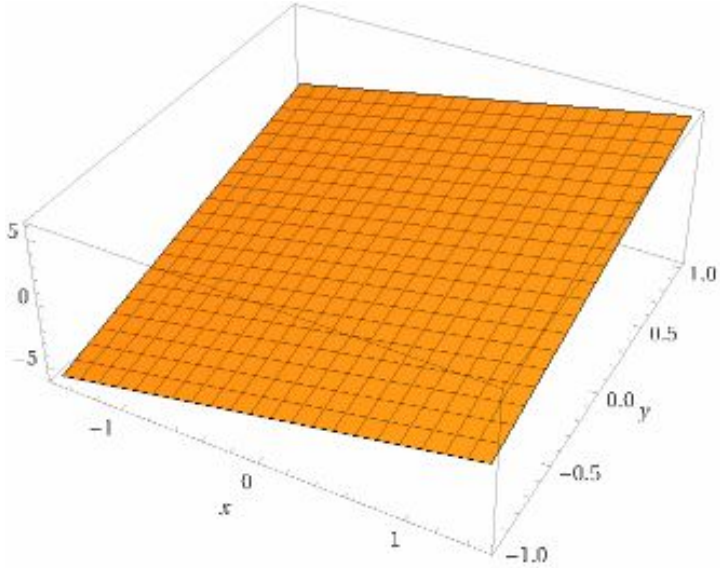

https://ja.wolframalpha.com/input?i=%E3%83%97%E3%83%AD%E3%83%83%E3%83%88+2+x+%2B+3+y

スカラ値関数をベクトルで微分する：その定義

- 定義：スカラ値関数をベクトルで微分するとベクトルになる

$$\frac{\partial f}{\partial \boldsymbol{x}} = \left[\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \ldots, \frac{\partial f}{\partial x_d}\right]^\top$$

各次元の偏微分

- 例えば以下のように計算される．公式として覚えておくと楽．

$$f(\boldsymbol{x}) = \boldsymbol{a}^\top \boldsymbol{x}$$

$$\frac{\partial f}{\partial x_i} = a_i \longrightarrow \frac{\partial f}{\partial \boldsymbol{x}} = \boldsymbol{a}$$

$$f(\boldsymbol{x}) = \boldsymbol{x}^\top \boldsymbol{x}$$

$$\frac{\partial f}{\partial x_i} = \frac{\partial}{\partial x_i} \sum_{j=1}^{d} x_j^2 = 2x_i \longrightarrow \frac{\partial f}{\partial \boldsymbol{x}} = 2\boldsymbol{x}$$

ベクトルを引数にとるベクトル値関数

$$\boldsymbol{x} \in \mathbb{R}^N \longrightarrow \boxed{f(\cdot)} \longrightarrow \boldsymbol{y} \in \mathbb{R}^M$$

- 例えば

$$\boldsymbol{f}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}$$

深層学習における線形層

- その微分は行列 (ヤコビ行列，ヤコビアン) になる

$$\frac{\partial \boldsymbol{f}}{\partial \boldsymbol{x}} = \left[\frac{\partial f_i}{\partial x_j}\right]_{ij}$$

出力側が列，入力側が行になるので注意．
(スカラ値ベクトルのときは，入力側が列)

例えば

- 前ページの例なら

$$\boldsymbol{x} \in \mathbb{R}^N \longrightarrow \boxed{\boldsymbol{f}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}} \longrightarrow \boldsymbol{y} \in \mathbb{R}^M$$

$$\frac{\partial \boldsymbol{f}}{\partial \boldsymbol{x}} = \boldsymbol{A}$$

- 連鎖律 (chain rule) も同様に適用可能
  - 信号処理システムを連結する．ニューラルネットワークを連結する

$$\boldsymbol{x} \in \mathbb{R}^N \longrightarrow \boxed{\boldsymbol{f}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}} \rightarrow \boldsymbol{y} \in \mathbb{R}^M \rightarrow \boxed{\boldsymbol{g}(\boldsymbol{y}) = \boldsymbol{C}\boldsymbol{y} + \boldsymbol{d}} \rightarrow \boldsymbol{z} \in \mathbb{R}^L$$

$$\frac{\partial \boldsymbol{g}}{\partial \boldsymbol{x}} = \frac{\partial \boldsymbol{g}}{\partial \boldsymbol{f}} \frac{\partial \boldsymbol{f}}{\partial \boldsymbol{x}} = \boldsymbol{C}\boldsymbol{A}$$

ニューラルネットワーク

どこまで理解している？

Do not edit
How to change the design

Presenting with animations, GIFs or speaker notes? Enable our Chrome extension

slido

単純パーセプトロン

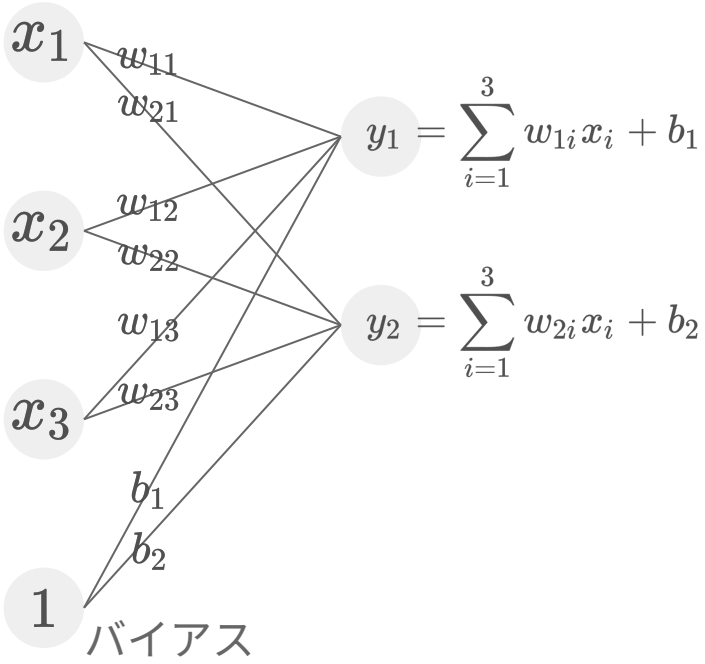

- 入力の各値を重みづけて足し合わせ
- つまるところアフィン変換

$$\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = \begin{pmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} + \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$$

$$\boldsymbol{y} = \boldsymbol{W}\boldsymbol{x} + \boldsymbol{b}$$

$$\boldsymbol{y} = [\boldsymbol{W}, \boldsymbol{b}][\boldsymbol{x}^\top, 1]^\top$$

- これだけだと多層でもアフィン変換

$$\boldsymbol{y} = \boldsymbol{W}_N \cdots \boldsymbol{W}_2 \boldsymbol{W}_1 \boldsymbol{x} = \boldsymbol{A}\boldsymbol{x}$$

- **活性化関数で非線形化**

活性化関数による非線形変換

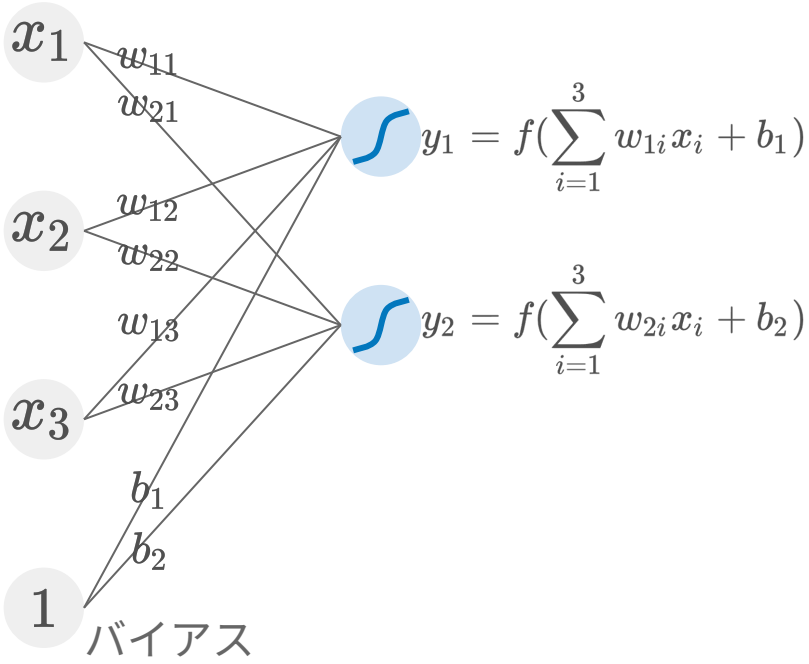

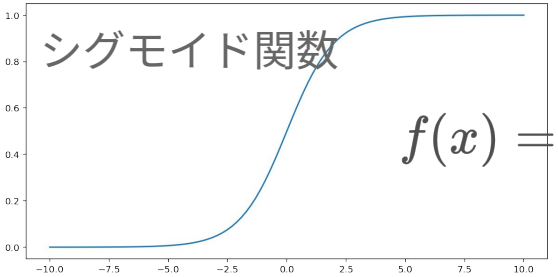

$$f(x) = \frac{1}{1+e^{-x}}$$

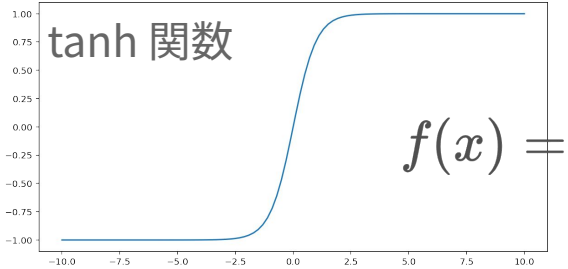

$$f(x) = \tanh(x)$$

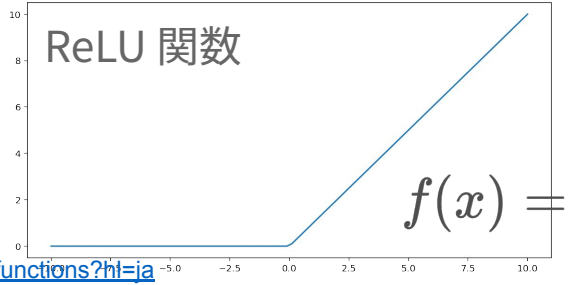

$$f(x) = \max(0, x)$$

https://developers.google.com/machine-learning/crash-course/neural-networks/activation-functions?hl=ja

多層パーセプトロン

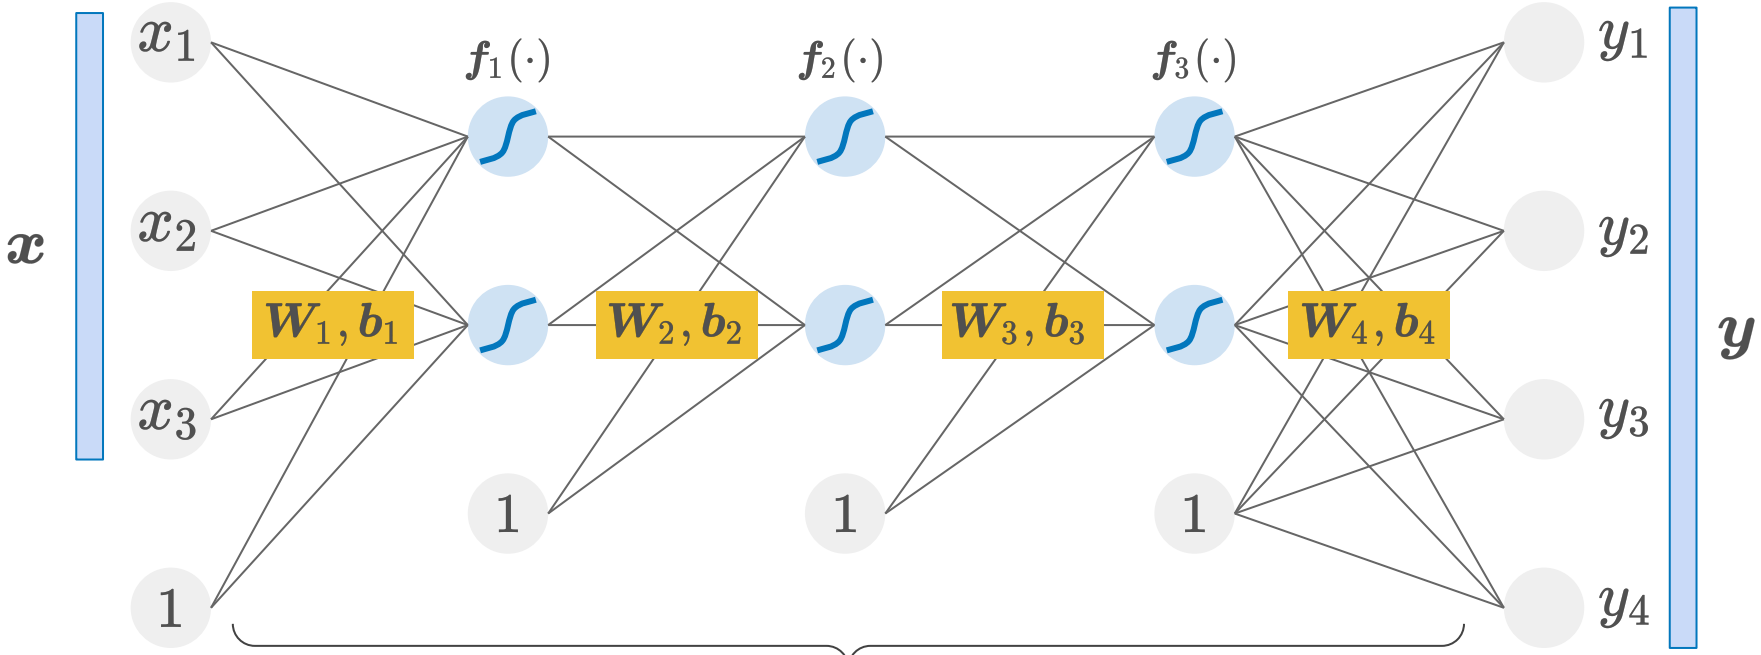

$\boldsymbol{y} = f_{\theta}(\boldsymbol{x})$ と表記

$\boldsymbol{W}_*, \boldsymbol{b}_*$ の集合 (パラメータθをもつ関数)

モデルパラメータ θ の学習

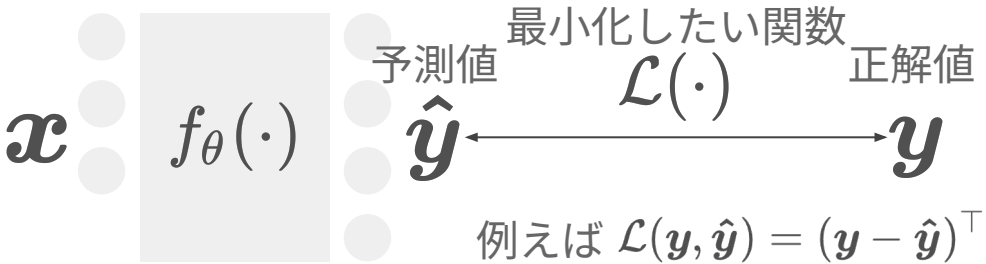

例えば $\mathcal{L}(\boldsymbol{y}, \hat{\boldsymbol{y}}) = (\boldsymbol{y} - \hat{\boldsymbol{y}})^\top (\boldsymbol{y} - \hat{\boldsymbol{y}})$ (二乗誤差)

関数の値を最小化する θ を求める (= 学習) するヒントはすでにある！

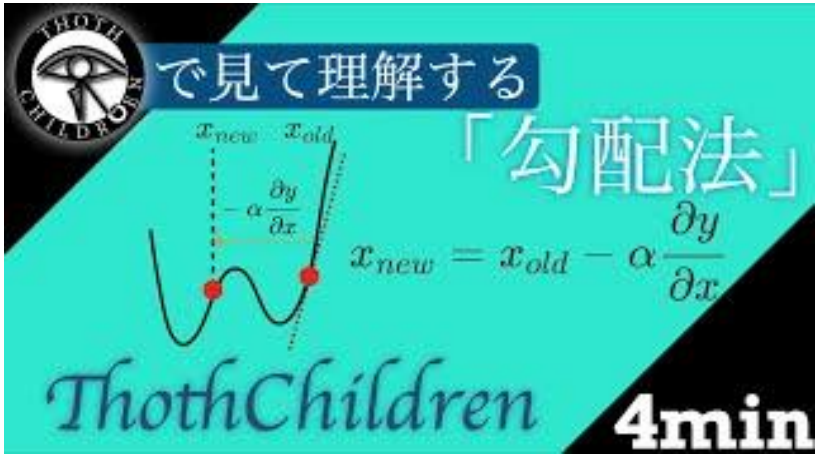

- 前ページの例なら

$$\boldsymbol{x} \in \mathbb{R}^N \longrightarrow \boxed{\boldsymbol{f}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}} \longrightarrow \boldsymbol{y} \in \mathbb{R}^M$$

$$\frac{\partial \boldsymbol{f}}{\partial \boldsymbol{x}} = \boldsymbol{A}$$

- 連鎖律 (chain rule) も同様に適用可能
  - 信号処理システムを連結する．ニューラルネットワークを連結する

$$\boldsymbol{x} \in \mathbb{R}^N \longrightarrow \boxed{\boldsymbol{f}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}} \longrightarrow \boldsymbol{y} \in \mathbb{R}^M \longrightarrow \boxed{\boldsymbol{g}(\boldsymbol{y}) = \boldsymbol{C}\boldsymbol{y} + \boldsymbol{d}} \longrightarrow \boldsymbol{z} \in \mathbb{R}^L$$

$$\frac{\partial \boldsymbol{g}}{\partial \boldsymbol{x}} = \frac{\partial \boldsymbol{g}}{\partial \boldsymbol{f}} \frac{\partial \boldsymbol{f}}{\partial \boldsymbol{x}} = \boldsymbol{C}\boldsymbol{A}$$

バックプロパゲーション

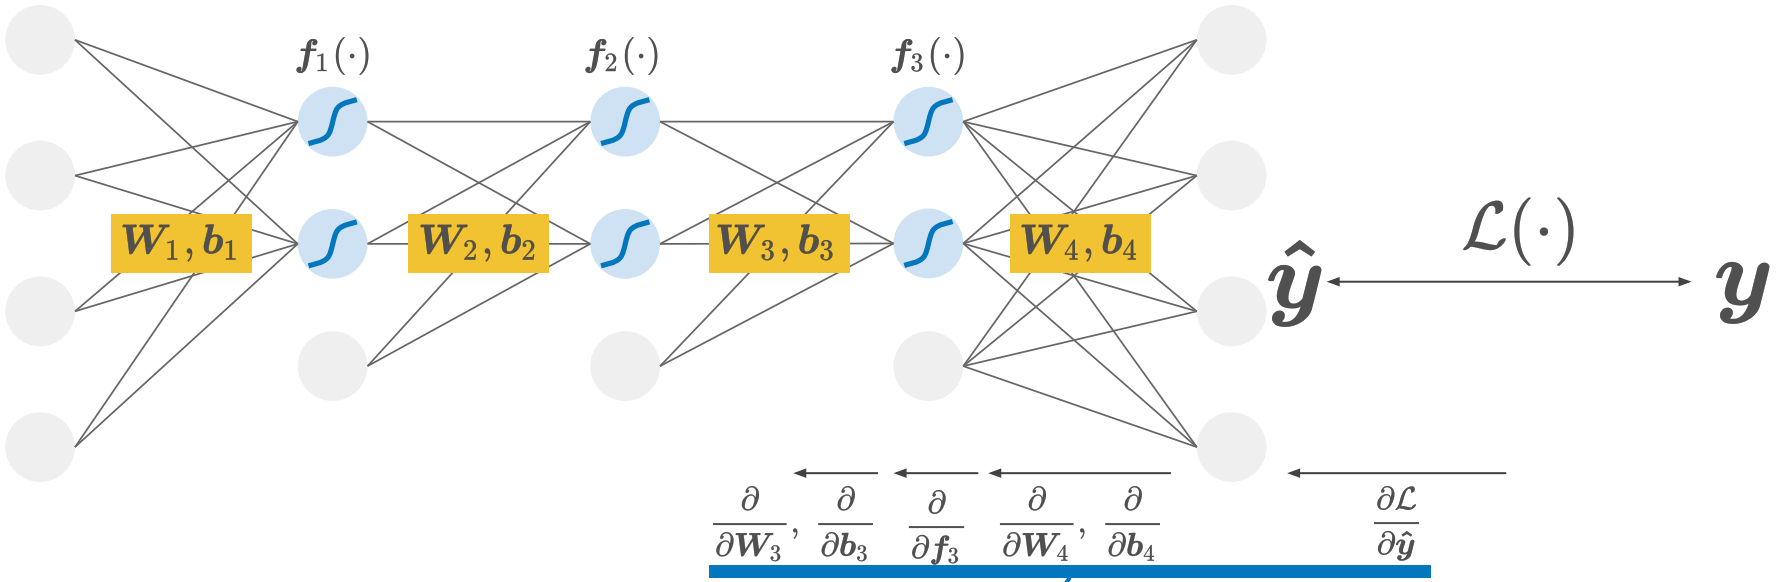

連鎖律で計算可能

$$W_3 \leftarrow W_3 - \alpha \frac{\partial \mathcal{L}}{\partial W_3}$$

更新後　更新前　目的関数の負の勾配

ソフトマックス関数

$$\sigma(\boldsymbol{y})_j = \frac{\exp(y_j)}{\underbrace{\sum_{\text{all } k} \exp(y_k)}}$$

exp した各要素の
割合だと解釈できる

exp を作用させたベクトル全要素で正規化

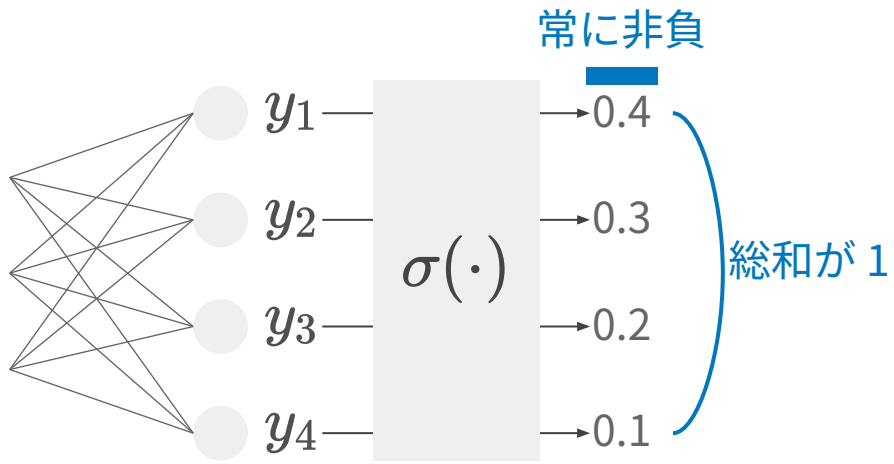

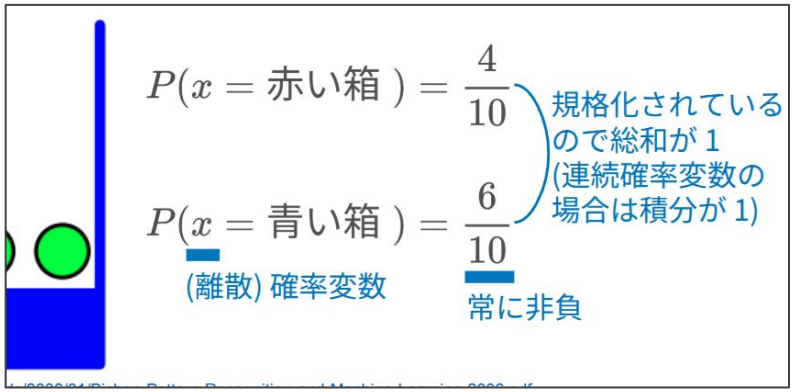

条件が同じ！すなわちニューラルネットワークの出力を確率と考えることができる

ニューラルネットワークを
離散確率変数の確率分布を出力するモデルだと考える

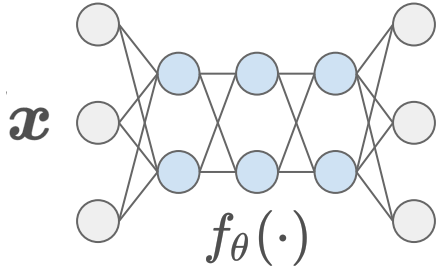

$p_\theta(\boldsymbol{y}|\boldsymbol{x})$

モデルパラメータ θ で計算される，
x に対する y の条件付き確率

“私”

単語を数値で
表現する
何らかの方法

次回以降に解説

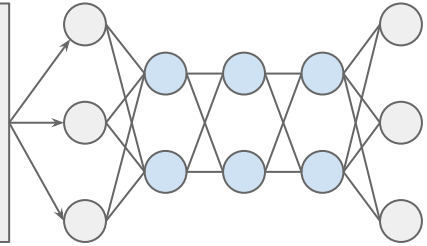

$P(\text{は}|\text{私})$

$P(\text{を}|\text{私})$

$P(\text{に}|\text{私})$

単語列で考えてみよう

私 / は / リンゴ / を / 食べる
彼 / は / バナナ / が / 好き / だ
私 / は / 公園 / に / 行く
リンゴ / が / 落ちる
私 / は / 赤い / リンゴ / を / 買う
空 / は / 青い
私 / は / 彼 / と / リンゴ / を / 分けた
彼女 / は / メロン / を / 食べる
私 / は / リンゴ / が / 大好き / だ
犬 / が / 走って / いる

50 単語の文章 (“/” は単語境界)

“私 は” の連続 2 単語の出現確率は？

$$P(\text{私}, \text{は}) = \underbrace{P(\text{は}|\text{私})}_{\text{“私”の後に“は”が出現する確率}}\underbrace{P(\text{私})}_{\text{“私”の出現確率}}$$

$P(\text{私}) = \frac{5}{50}$ (50 単語のうち 5 回出現)

$P(\text{は}|\text{私}) = \frac{5}{5}$ (“私” に後続する 5 単語のうち 5 回出現)

連続 3 単語以上にも拡張可能

$$P(\text{私}, \text{は}, \text{彼}) = P(\text{彼}|\text{は}, \text{私})P(\text{は}|\text{私})P(\text{私})$$

条件付き確率を計算する，
パラメータ Θ を持つニューラルネット

まとめ

まとめ

- 確率
  - 条件付き確率，同時確率，連鎖律，単語列で確率を考える
- 線形代数
  - ベクトル・行列の和・積，一次変換，アフィン変換
- 微分
  - ベクトルを微分，ベクトルで微分
- ニューラルネットワーク
  - 多層パーセプトロン，確率値を出力するニューラルネットワーク

課題

- https://github.com/takamichi-lab/nlp-lecture-keio/tree/main/2026/codes/02 にアクセスせよ．

- 以降のページに示す python コードを実装し，コードと出力結果を載せた pdf を提出せよ．

- LLM や code assist を使用しても構わないが，まずは自分で解くこと．
  - 使用した場合は，どう使用してどう反映したかも pdf に書くこと．
  - 使用したにも関わらず使用に関する記載がない場合は 0 点とする．

文字 n-gram (連続する n 文字) の確率を計算せよ

data.txt

```
いあいいあういいういいいうあううあいいいいううい
あういあああああいいういいあいいううあうあいあい
いああうあいうあいあういうういいういあいういうあ
うああういううううあいあういいいいあいいういあああ
```

```python
# 課題： data.txt を読み込んで，文字の n-gram (n = 1, 2) を
# 表示するプログラムを作成してください．
# すでに書かれている箇所は変更しても構いません．

def n_gram(text, n):
    """テキストを n-gram に分割する関数"""


if __name__ == "__main__":
    """メイン関数"""

    unigram = n_gram(text, 1)
    bigram = n_gram(text, 2)

    # 1-gram (unigram, ユニグラム)
    print("あ", unigram["あ"])
    print("い", unigram["い"])
    print("う", unigram["う"])

    # 2-gram (bigram, バイグラム)
    print("あ あ", bigram["あ あ"])
    print("あ い", bigram["あ い"])
    print("あ う", bigram["あ う"])
    print("い あ", bigram["い あ"])
```

“あ” が出現する確率
(“あ”の出現回数 / 全文字数)

“あ” と “あ” が連続して出現する確率

条件付き確率を計算するニューラルネットワークを構築せよ

```python
# "あ", "い", "う" のいずれかを入力とし、
# 次元数 3 の確率値を出力するニューラルネットワークを構築してください
# ニューラルネットワークの構成，使用する Python モジュールは問いません.
# 学習は不要で，重みは適当に（例えば乱数値に）設定してください.
# 例：入力 "あ" に対して，出力 [0.7, 0.2, 0.1] を得る.
# すでに書かれている箇所は変更しても構いません.

input_vec = {
    "あ": [1, 0, 0],
    "い": [0, 1, 0],
    "う": [0, 0, 1]
}

def neural_network(input_char):
    """ニューラルネットワークの関数"""

    return output_vec # 3次元の確率値を返す


if __name__ == "__main__":
    """メイン関数"""

    output_a = neural_network("あ")
    output_i = neural_network("い")
    output_u = neural_network("う")

    print("入力: あ, 出力:", output_a) # 全要素は非負の値で，合計は 1 でなければならない
    print("入力: い, 出力:", output_i)
```

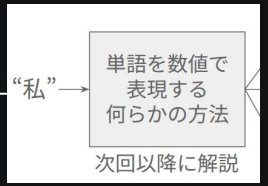

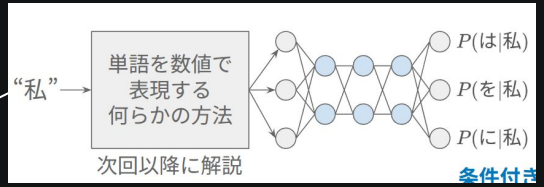

学習は不要．すなわち，
“あ” “い” “う” の入力から
確率値の条件を満たす
何らかの値が出ればOK