

自然言語処理 2026 演習問題

Day01

1. 予測プロセスとして「特徴抽出」「スコア計算」「決定」の3つのステップがある。各ステップの役割を簡潔に説明せよ。
2. 機械学習ベースのシステムでは「学習データ量の対数に性能が比例する傾向」がある。今、学習データ量を D 、システムの性能を P とし、比例定数を k として $P = k \log_{10} D$ という関係式が成り立つと仮定する。学習データ量を元の100倍に増やした場合、システムの性能 P は元の性能と比べてどれだけ増加するか答えよ。
3. 規則ベースの分類器で、テキストから「ポジティブ単語の数 (x_1)」と「ネガティブ単語の数 (x_2)」を特徴抽出する。スコア S の計算式が $S = 2x_1 - 3x_2$ と手動設定されているとき、ある文章から $x_1 = 5, x_2 = 2$ が抽出され、スコアは $S = 4$ であった。重みの手動調整として、ネガティブ単語のペナルティ（重み）を3から w_2 へ変更し、同じ文章のスコアを $S = 1$ に下げたいとき、変更すべき新しい重み w_2 の値を求めよ。
4. 自然言語と人工言語の定義を述べ、自然言語に該当する言語を10個挙げよ。

Day 02

1. 以下の10個の文（総単語数50単語）からなるミニコーパスがある。このとき、3単語の系列「私 / は / リンゴ」がこの順に連続して出現する同時確率を、連鎖律を用いて計算せよ。
 - (a) 私 / は / リンゴ / を / 食べる
 - (b) 彼 / は / バナナ / が / 好き / だ
 - (c) 私 / は / 公園 / に / 行く
 - (d) リンゴ / が / 落ちる
 - (e) 私 / は / 赤い / リンゴ / を / 買う
 - (f) 空 / は / 青い
 - (g) 私 / は / 彼 / と / リンゴ / を / 分けた
 - (h) 彼女 / は / メロン / を / 食べる
 - (i) 私 / は / リンゴ / が / 大好き / だ
 - (j) 犬 / が / 走って / いる
2. 同じサイズの2つの行列 $A = \begin{pmatrix} 2 & 0 \\ -1 & 4 \end{pmatrix}$, $B = \begin{pmatrix} 3 & 5 \\ 2 & -2 \end{pmatrix}$ があるとき、そのアダマール積 $A \odot B$ を計算せよ。
3. 2次元の入力ベクトル $\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$ を引数にとり、スカラ値を返す関数 $f(\mathbf{x}) = 3x_1^2 + 2x_1x_2 + 5x_2^2$ がある。このとき、このスカラ値関数をベクトル $\mathbf{x}$ で偏微分した結果である勾配ベクトル $\frac{\partial f}{\partial \mathbf{x}}$ を求めよ。

4. あるニューラルネットワークの出力（予測値）ベクトルが $\mathbf{y} = \begin{pmatrix} 0.8 \\ 0.2 \\ 0.1 \end{pmatrix}$ であり、それに対する実際の正解（ターゲット）ベクトルが $\mathbf{t} = \begin{pmatrix} 1.0 \\ 0.0 \\ 0.0 \end{pmatrix}$ であった。この予測に対する平均二乗誤差の値を求めよ。
5. ニューラルネットワークのある出力層の手前のベクトル（ロジット）が $\mathbf{a} = \begin{pmatrix} \log 2 \\ \log 3 \\ 0 \end{pmatrix}$ と与えられたとする。このベクトルに対しソフトマックス関数を作用させた結果のベクトル $\mathbf{y} = \text{softmax}(\mathbf{a})$ を求めよ。

Day 03

- 語彙的関係の定義において、「顔 > 目、鼻、口」や「自動車 > エンジン」のように、物理的に含む・含まれる関係（Has-a 関係）を何と呼ぶか：(A) 同義関係、(B) 上位・下位関係、(C) 関連語関係、(D) 全体・部分関係。
- 「ここにパン屋があるよ」という文字列が、ピッチ（音調）の下降によって「事実を伝える」意味になり、上昇によって「疑問を投げかける」意味になるという現象は、何論的曖昧性の例か：(A) 統語論的曖昧性、(B) 意味論的曖昧性、(C) 音韻論的曖昧性、(D) 形態論的曖昧性
- 語用論的曖昧性が生じる文を1つ挙げ、その曖昧性を説明せよ。ただし、講義スライドに含まれる例は不可とする。
- 「ワインが半分残っている」と「ワインが半分しか残っていない」の例のように、同じ外界を観測したとしても異なる認知の発露が生じる。同様に、異なる認知の発露が発生したと思われる文対を挙げ、その認知過程を「前景化」「背景化」という言葉を使って説明せよ。ただし、飲み物・食べ物・液体に関する文は不可とする。

Day 04

- 語彙数（単語の集合の大きさ） $|V| = 5000$ のコーパスが存在する。このとき、各単語を one-hot ベクトルで表現した場合、このベクトルの次元数を答えよ。
- 語彙数 $|V| = 5000$ の単語を 100 次元の単語埋め込みに変換するとき、単語埋め込み層のもつ、学習可能なパラメータ数を答えよ。
- Word2Vec の基盤となる分布仮説とはどのような考え方か、簡潔に説明せよ。
- LLM 時代において、単語単位ではなくサブワード単位の語彙獲得が主流となっているメリットを、未知語（OOV）の観点から説明せよ。

Day 05

- 語彙数 $|V| = 20,000$ の言語において、4-gram 言語モデルを構築する場合、理論上存在しうる条件付き確率のパラメータの総数は最大でいくつになるか答えよ。
- ある3つの単語からなるテスト文 $X = (w_1, w_2, w_3)$ がある。ある自己回帰型言語モデルが予測した各ステップの正解単語の出力確率が、 $P(w_1) = 0.5, P(w_2 | w_1) = 0.25, P(w_3 | w_1, w_2) = 0.125$ だったとする。このとき、この文 X に対するモデルの負の対数尤度（NLL）の値を計算せよ。ただし、対数の底は 2 とする。
- RNN 言語モデルにおいて、語彙数が 2^{10} 、単語埋め込みの次元数が 2^5 、隠れ状態（内部状態）の次元数が 2^6 であったとする。このとき、1 層 RNN 言語モデルが持つ、学習可能なモデルパラメータ数（単語埋め込み層を含む）を答えよ。ただし簡単のため、バイアス項は存在しないものとする。

Day 06

1. 単語境界推定において、BIO タグがどのように使用されるかを、具体的な例文を挙げて説明せよ。ただし、講義スライドにある文例は不可とする。
2. FF (Feed-Forward) 型エンコーダ、単方向 RNN 型エンコーダ、非因果性 CNN 型エンコーダ (ウィンドウサイズ前後 $N = 1$) の3つを考える。ある文章の「4 番目の単語」の特徴量を計算する際、それぞれのエンコーダが参照する単語の数をそれぞれ答えよ。
3. Cross Attention のメカニズムにおいて、出力側のデコーダから抽出されたクエリベクトル $\mathbf{q} \in \mathbb{R}^3$ が1つある。入力側のエンコーダには3つの単語があり、それぞれのキーベクトルが $k_1, k_2, k_3 \in \mathbb{R}^3$ 、バリューベクトルが $v_1, v_2, v_3 \in \mathbb{R}^2$ として与えられている。いま、クエリと各キーの内積を計算したところ、 $[q^\top k_1, q^\top k_2, q^\top k_3] = [0, \ln 3, \ln 2]$ となったとする。このとき、Softmax で正規化された Attention 値 (重み) のベクトルと、最終的に得られるコンテキストベクトル (重み付き加算されたバリューベクトル) を v_1, v_2, v_3 を用いた数式で答えよ。