

慶應義塾大学 理工学部 情報工学科 自然言語処理 (2026/07/09)

13 - 言語やラベルを評価する

情報工学科 准教授 高道 慎之介



Takamichi Laboratory
慶應義塾大学 高道研究室

講義予定

第XX回	日付	内容（順次変わっていくので予想）	
第01回	2026/04/09	イントロダクション	事前知識の確認
第02回	2026/04/16	自然言語処理のための機械学習に入門する	
第03回	2026/04/23	言語学に入門する	言語とは何だろう
第04回	2026/04/30	単語をベクトルで表現する	自然言語処理の基礎技術
第05回	2026/05/07	言語モデルで文章を統計的に扱う	
第06回	2026/05/14	系列にラベリングする	
第07回	2026/05/21	演習 1	これまでの復習
第08回	2026/05/28	Transformer を理解する	大規模言語モデル時代の技術
第09回	2026/06/11	言語モデルを事前学習する	
第10回	2026/06/18	言語モデルを転移学習する	
第11回	2026/06/25	言語を生成 (デコーディング) する	
第12回	2026/07/02	言語やラベルを評価する	
第13回	2026/07/09	自然言語処理から音声言語処理へ	おまけ
第14回	2026/07/16	演習 2	これまでの復習
期末試験	2026/07/XX	(日程は後日アナウンス)	

復習：大規模言語モデルから言語を生成

Decoder-only 型の事前学習




次トークン予測 (next token prediction)で学習

- t 番目の単語を，それ以前の単語から予測

Encoder-decoder 型と比べて

- KV キャッシュによる計算高速化が可能 (課題)
- 推論コストが小さい
 - encoder は self-attention で双方向計算を行うため重い
 - decoder は過去トークンのみ
- 長文に対する推論コストが小さい


出力の候補はグラフと見做すことができる



生成においてやること：最尤パスを求めること

(=確率の積が最も高くなる単語列を求めること)


$$\hat{\mathbf{y}} = \operatorname{argmax} P(\mathbf{y}) = \operatorname{argmax} \prod_{n=1}^N P(y_n | y_{<n})$$



最尤からサンプリングへ

「確率の高い候補を残す」ではなく、
確率に基づいてランダムに選ぶ。

ただし、確率値の顕著に低いものは
不自然な文になるため、ある程度
確率値が高いものだけを使う！



今日の目的： 生成された言語を評価する



なぜ評価するのか？

なぜ評価が大事なのか？

種々の学習済み LLM から目的に最適なものを選ぶため

全てのタスクが得意な LLM は存在しない。必要な能力を持つ LLM を選ぶ必要がある。
また、その能力は定量化されているべきである。

LLM を改善させるためのより良い方法やデータを探ること

学習・推論に関してどんな方法やデータを採れば、所望する能力が得られるかを調査する。

LLM の成長過程をモニターするため

LLM の学習コストは非常に大きい。その仮定でモデルの成長過程を観察し、よりよい成長手段を図る。

種々の学習済み LLM から目的に最適なものを選ぶため：リーダーボードを使う

<https://arena.ai/leaderboard/text/overall> (ユーザ評価に基づく)

View as

RankingPareto

Categories (29)

Overall

Expert Learn more →

Occupational

Math

Instruction Following

Multi-Turn

Creative Writing

Coding

Text Arena Overall

View overall rankings across various AI models in text-to-text tasks across math, coding, creative writing, and other open-ended domains.

Jul 2, 2026 7,152,929 votes 369 models

Hide Filters

Rank by Models Labs

Rank	Rank Spread	Model	Score	Votes	Price
1	1 - 4	AI claude-fable-5 Anthropic · Proprietary	1509 ±9	4,350	\$
2	1 - 4	AI claude-opus-4-6-thinking Anthropic · Proprietary	1504 ±4	55,102	\$
3	1 - 5	AI claude-opus-4-7-thinking Anthropic · Proprietary	1502 ±4	41,868	\$
4	1 - 5	AI claude-opus-4-6 Anthropic · Proprietary	1499 ±4	58,565	\$
5	3 - 6	AI claude-opus-4-7 Anthropic · Proprietary	1494 ±4	43,053	\$


<https://swallow-llm.github.io/leaderboard/index-post.ja.html> (日本語特化)



LLM の成長過程をモニターするため： データ，事前学習，事後学習の効果を図る

事前学習の効果をモデルサイズに 対して図る

あるモデルサイズを超えると，スケーリング則を超えて
急に性能が向上する




<https://arxiv.org/pdf/2206.07682>

35

自然言語処理 第 09 回スライドから引用

種々の PEFT 手法の効果を図る

種々のタスクで頑健に動作



<https://arxiv.org/pdf/2106.09685>

41

自然言語処理 第 10 回スライドから引用

伝統的な NLP タスク

二値分類タスクを考える

容認性判断 (文法的か否か, from CoLA (Corpus of Linguistic Acceptability))

- The **keys** to the cabinet **are** on the table. → 正解は Positive
- The **keys** to the cabinet **is** on the table. → 正解は Negative

<https://nyu-ml.github.io/CoLA/>

推論能力を問う質問 (from BoolQ corpus)

- 宝くじの当選金に税金はかかる? → 正解は No (Negative)

https://www.anlp.jp/proceedings/annual_meeting/2024/pdf_dir/C3-3.pdf

文章分類 (document classification)

- 今後の業務連絡および緊急時の連絡体制強化のため、LINEでの連絡網を整備いたします。
つきましては、ご自身のLINEのQRコードを本メールへご返信いただけますようお願いいたします。
確認後、順次LINEグループへご案内いたします。


 → 正解は Yes (スパムメール)

混同行列 (confusion matrix)

二値分類において識別性能を定量化するための表。対角要素が大きいほど好ましい

		正解	
		Positive	Negative
予測	Positive	TP (True Positive)	FN (False Negative)
	Negative	FP (False Positive)	TN (True Negative)

Accuracy, Precision, Recall, Specificity



Accuracy (精度)

正解

	Pos	Neg
予測 Pos	TP	FN
Neg	FP	TN

どれだけ正確に
予測できたか

Precision (適合率)

正解

	Pos	Neg
予測 Pos	TP	FN
Neg	FP	TN

Positive と予測した
ものが本当にPositive
である割合

Recall (再現率)

正解

	Pos	Neg
予測 Pos	TP	FN
Neg	FP	TN

本当はPositiveだった
ものをPositiveと予測
できる割合

Specificity (特異度)

正解

	Pos	Neg
予測 Pos	TP	FN
Neg	FP	TN

本当はNegativeだった
ものをNegativeと
予測できる割合

GLUE：言語モデルの性能を測るベンチマーク集

各コーパスには、各能力を測るための質問文と正解ラベルが含まれる。
タスクを深化させた SuperGLUE もある。

	Corpus	Train	Test	Task	Metrics	Domain
	Single-Sentence Tasks				1文のみの評価	
容認性 極性分類	CoLA	8.5k	1k	acceptability	Matthews corr.	misc.
	SST-2	67k	1.8k	sentiment	acc.	movie reviews
	Similarity and Paraphrase Tasks				類似，言い換え	
言い換え 意味類似	MRPC	3.7k	1.7k	paraphrase	acc./F1	news
	STS-B	7k	1.4k	sentence similarity	Pearson/Spearman corr.	misc.
	QQP	364k	391k	paraphrase	acc./F1	social QA questions
	Inference Tasks					
	MNLI	393k	20k	NLI	matched acc./mismatched acc.	misc.
	QNLI	105k	5.4k	QA/NLI	acc.	Wikipedia
	RTE	2.5k	3k	NLI	acc.	news, Wikipedia
	WNLI	634	146	coreference/NLI	acc.	fiction books

JGLUE：日本語版GLUE

(中国語は CLUE，フランス語GLUE もある)

MARC-ja

レビュー文の極性を問う

レビュー文章	レーティング	ラベル
大切な友人の誕生日にはかならず贈る 1 冊。	5	positive
きれいな商品でした。また安くて良いものをお願いします。	4	positive
組み立ての説明が日本語対応でない付属のモーターでは非力すぎる	2	negative

JSTS, JNLI

意味的類似度と
自然言語推論

文 1 / 前提文	文 2 / 仮説文	類似度	推論関係	
街中の道路を大きなバスが走っています。	道路を大きなバスが走っています。	4.4	entailment	含意
テーブルに料理がならべられています。	テーブルに食べかけの料理があります。	3.0	neutral	
野球選手がバットをスイングしています。	野球選手がキャッチボールをしています。	2.0	contradiction	矛盾

JSQuAD

機械読解

[タイトル] 東海道新幹線

1987 年（昭和 62 年）4 月 1 日の国鉄分割民営化により、JR 東海が運営を継承した。西日本旅客鉄道（JR 西日本）が継承した **山陽新幹線**とは相互乗り入れが行われており、東海道新幹線区間のみで運転される列車にも JR 西日本所有の車両が使用されることがある。2020 年（令和 2 年）3 月現在、東京駅 - 新大阪駅間の所要時間は最速 **2 時間 21 分**、最高速度 285km/h で運行されている

質問: 2020 年、東京～新大阪間の最速の所要時間は

正解: **2 時間 21 分**

質問: 東海道新幹線と相互乗り入れがされている路線はどこか？

正解: **山陽新幹線**

JCommonsenseQA

常識推論

質問: 会社の最高責任者を何というか？

選択肢: 教師, 部長, **社長**, 部下, パイト

質問: スープを飲む時に使う道具は何？

選択肢: **スプーン**, メニュー, 皿, フォーク, はし

文生成タスクを考える（答えは1つでないことに注意）

翻訳

- a General Translation Task
- a Low-Resource Indic Language Translation
- a Low-Resource Arabic-Asian Language Translation Task
- a Chinese-Southeast Asian Multilingual MT Task

- a Terminology Shared Task
- a Creole Language Translation Task
- a Video Subtitle Translation Task
- an MT Test Suites Subtask

<https://www2.statmt.org/wmt26/>

マルチターン対話応答 (from Japanese MT-bench)

- "人生の各段階は、我々が時間や死をどう理解するかにどのように影響を与えるでしょうか？例を挙げて説明してください。", [ユーザ回答], "上記を表現した寓話的な詩を作成してください。", [ユーザ回答]

https://github.com/Stability-AI/FastChat/tree/jp-stable/fastchat/llm_judge/data/japanese_mt_bench

算術計算 (from MGSM)

- ロープを作成するには、青色の繊維を2巻分、白色の繊維をその半分用いる必要があります。全体で何巻必要ですか？ → 3

BLEU：単語 n-gram の適合率 (precision)

システム出力文 (hypothesis) に含まれる単語 n-gram が、
参照文 (正解文, reference) にどの程度含まれるか。

$$\text{BLEU} = \text{BP} \times \exp \left(\sum_{n=1}^4 \frac{1}{4} \log_e p_n \right)$$

1-, 2-, 3-, 4-gram を重みづけ

$$p_n = \frac{\min(\text{n-gram 一致数, ref の n-gram 数})}{\text{hypothesis に含まれる n-gram 数}}$$

n-gram の適合率

$$\text{BP} = \min \left(1, \exp \left(1 - \frac{\frac{\text{正解文の長さ}}{|\text{reference}|}}{\frac{\text{出力文の長さ}}{|\text{hypothesis}|}} \right) \right)$$

出力文が短すぎる
ことに対する罰則

参照文: The NASA Opportunity rover is battling a massive dust storm on Mars.

候補訳 1: The Opportunity rover is combating a big sandstorm on Mars.

$precision_1$ (1 グラム)	8/11
$precision_2$ (2 グラム)	4/10
$precision_3$ (3 グラム)	2/9
$precision_4$ (4 グラム)	0/8
Brevity Penalty	0.83
BLEU スコア	0.0

他にも

chrF

文字 n-gram の一致度に基づく重み付き F値．単語分割の問題（語形変化など）を緩和．

ROUGE

BLEUの適合率に対し，こちらは再現率で計算．ROUGE-L では最長共通部分列も考慮．

METEOR

単語列同士のアライメントに基づく計算．

注意：これらの指標値は前処理に強く依存する

Case sensitivity

大文字と小文字を区別するか？

- 正解文：This / is / a / pen.
- 出力文：this / is / a / pen.

This と this を区別するかでスコアが変わる

Punctuation handling

句読点を1つの単語として数えるか

- 正解文：こんにちは世界
- 出力文：こんにちは、世界。

「，．」をカウントするかでスコアが変わる

Tokenizer choice

どの形態素解析器を用いるか？

- 正解文：外国人 / 参政権
- 出力文：外国 / 人参 / 政権

形態素の区切りは解析器に依存する

Unit level

単語レベル？文字レベル？

- 正解文：京都 / ヘ
- 出力文：東京都 / ヘ

単語なら2語中1語×。
文字なら4文字中1文字×

Whitespace handing

スペース(の連続)はどうする？

- 正解文：Language__model
- 出力文：Language_model

スペースの連続は
スペース1つに置換する？

ニューラル言語モデル時代の評価

文字表層に基づく評価の限界

なぜダメ？

- 表層の一致 $\neq$ 意味の一致
- 語順の一致 $\neq$ 意味の一致
- **結果として、人間の評価と自動評価が相関しない！**

解決策

- 単語や文を数値表現できるニューラル言語モデルを使えば良い！
 - 意味の近さなどをベクトル類似度で表現できる
- 人間の主観評価値を自動予測する機械学習モデルを作ればよい！

n-gram 言語モデルの限界

限界1：関係単語を扱えない

私 は 車 を 買った
↓ 同義関係だが別扱い
私 は 自動車 を 買った

語彙的関係の定義 (シソーラス、オントロジー辞書に収録)

同義関係	上位・下位関係	全修・部分関係
定義： 「ほとんど」全ての文脈で置き換え可能な単語	定義： 単語の全性質を保持しつつ、上位語の上位語 (母語) となる関係	定義： 概念的に含む・含まれる関係 (hypernymy)
具体例： • 車、自動車 • 二輪自動車、軽自動車、CD2 → 異なる文脈性があるため、互換性がない	具体例： • 軽自動車 > 車、車 > 自動車 • 乗用車 > テンポ → 上位語の性質を保持する関係、上位語で置き換えることが可能	具体例： • 車 > 軽自動車、車 > トラック • 自動車 > エンジン → 上位語の性質を保持しない関係、置き換えることができない

第03回スライドから引用

→ 解決策：class-based n-gram モデル

限界2：離れた単語を扱えない

美味しい とは 全く 思わ ない
否定：美味しいの否定が離れている


鍵 を 失くして それ を 探した
照応：代名詞の指す内容が離れている

→ 解決策：skip-based モデル


復習：BERTの事前学習

2文が関係していることを学習。
例えば質問文に対する回答文
→ 文レベルの埋め込みを学習

周りの単語から隠れた単語を予測するように学習
→ 分布仮説に基づいた「文脈による表現学習」
(得られたベクトルは“文脈”単語埋め込みと呼ばれる)




BERTScore：評価文と参照文の文脈単語埋め込みの類似度を比較する



- 出力文と正解文それぞれから、文脈単語埋め込み系列を生成
- 埋め込みの全組み合わせに対しコサイン類似度を計算
- 計算の亜種がある
 - 出力文単語ごとに平均 (precision)
 - 正解文単語ごとに平均 (recall)
 - その調和平均 (F1)

MoverScore: Earth Mover 距離に基づく類似度計算




- BERTScore は出力文と正解文の各単語の1対1対応を仮定する
- MoverScore は多対多の対応を許す。
- 最適輸送問題 (Optimal transport) である「ある文のベクトル集合を、もう一方の文のベクトル集合へ変形・移動させるのに必要な最小コスト」を計算する。
 - 詳しく知りたい人は
<https://speakerdeck.com/eumesy/optimal-transport-for-natural-language-processing>

補足：Earth Mover's distance (ワッサーシュタイン距離)

Wasserstein Distance


A DATA SCIENCE ESSENTIAL



前置き：教師あり学習に基づく予測

良い自動評価は，人間による主観評価と強く相関している

→ 主観評価値を学習データとして，主観評価値を予測する教師あり学習モデルがあればよいのでは？




人間による主観評価を実施して
事前に獲得

COMET：埋め込み平均を使ってスコアを予測


予測スコア

(正解スコアとの二乗誤差を最小化して学習)




スコア予測の
デコーダ

- 翻訳品質の自動評価
- スコア予測に必要な特徴量を
単語埋め込みから計算
- 主観評価値を教師あり学習に用いる
方法は昔からあったが、優れたエン
コーダによって高精度化
 - 例えば多言語BERT



LLM as a judge

コンセプト：言語モデルが評価しよう



なぜそんなことを考える必要がある？

- LLMの能力が強力になるほど、実世界の問題を解けるようになった
- 出力文の良さを図るときに、評価軸が複雑かつ主観的（例えばニュアンス）になり、単純な表層の一致（例えばBLEU）では図れなくなった。
- 確実な方法は専門家が出力文を評価することだが、
人的・時間的・金銭的成本が増大し、膨大データに対応できない。
- そこで、専門家の代わりに複雑かつ主観的な評価を返してくれる
「評価者としてのLLM」を作れないか、という考えが進行

日本語用 LLM as a judge を覗いてみよう

<https://github.com/llm-jp/llm-jp-judge>

https://github.com/llm-jp/llm-jp-judge/blob/main/src/llm_jp_judge/evaluator/quality.py

The screenshot shows the GitHub repository page for `llm-jp-judge`. The repository is public and has 5 watchers, 2 forks, and 43 stars. It is currently on the `main` branch, with 9 other branches and 3 tags. The repository was created by `k141303` 7 months ago and has 126 commits. The file list includes `scripts`, `src/llm_jp_judge`, `.gitignore`, `LICENSE`, `README.md`, and `requirements.txt`. The `README.md` file is selected, showing the title `llm-jp-judge` and the description: "日本語 LLM-as-a-Judge を統合的に扱うためのツール". The repository is licensed under Apache-2.0. The right sidebar shows the `About` section with the description "生成自動評価を行うためのPythonツール", the `Releases` section with the `Initial Release` on Mar 11, 2025, and the `Packages` section with the message "No packages published".

llm-jp-judge Public

Watch 5 Fork 2 Star 43

main 9 Branches 3 Tags

Go to file Add file Code

k141303 GPT-5に対応 (#43) 0ddf575 · 7 months ago 126 Commits

scripts	llm-jp-instructionsのダウンロードを追加	last year
src/llm_jp_judge	GPT-5に対応 (#43)	7 months ago
.gitignore	add data/cache	last year
LICENSE	Create LICENSE	last year
README.md	GPT-5に対応 (#43)	7 months ago
requirements.txt	version固定	last year

README Apache-2.0 license

llm-jp-judge

日本語 LLM-as-a-Judge を統合的に扱うためのツール

[llm-jp-judge: 日本語LLM-as-a-Judge評価ツール](#)

About

生成自動評価を行うためのPythonツール

- Readme
- Apache-2.0 license
- Activity
- Custom properties
- 43 stars
- 5 watching
- 2 forks

Report repository

Releases 1

Initial Release Latest on Mar 11, 2025


Packages

No packages published

どの種類で評価するか？


スコアを生成する

リッカート尺度, 連続値, etc



Yes/No, 多肢選択, 比較

どれだけ正確に予測できたか



どの LLM で評価するか？

ChatGPT などの API を利用する

- メリット：(大規模に学習されているため) 評価軸によっては主観評価値と相関する。
- デメリット：データが外部に漏洩する。API仕様変更で結果の再現が困難になる。


ローカルLLMを LLM-as-a-judge 用に fine-tuning する

- メリット：データ漏えいは無く、結果の再現は可能。
- デメリット：APIのものより相関が悪くなりやすく、またバイアスも生じやすい。
 - 自己選好バイアス：生成用LLMと評価用LLMが同じ時にスコアが高くなりやすい
 - 文化バイアス：学習に使われていない文化圏の言語や文化を評価できない
 - 位置バイアス：複数選択肢が、内容でなく登場順で選ばれる傾向

GPTScore

評価軸ごとにプロンプトのテンプレートを作成．評価軸の説明とサンプル例も載せる．最後に評価対象の文を追加し，その部分の確率を計算する．

意図は「**評価対象文が説明文に従った情報を持っているなら高い確率を示すはず**」．



$$\text{GPTScore}(\mathbf{h}|d, a, S) = \sum_{t=1}^m w_t \log p(h_t | \mathbf{h}_{<t}, T(d, a, S), \theta),$$

まとめ

Conclusion

まとめ

- 言語モデルの評価が大事
- 基本的な NLP タスクを評価する
 - 2 値分類, 文章生成
 - 混同行列, BLEU, etc.
- ニューラル言語モデルを使った評価
 - BERTScore や MoverScore による類似度比較
 - COMET などの教師あり学習
- LLM as a judge
 - タスクの複雑化により, 文章を評価する役割の LLM が登場

第 14 回について

- 第 08 ~ 13 回の内容を理解しているかを問う課題を出します。
 - Gemini に聞けば答えがわかるように設計しておきます。
- 出張のため、高道は開始 15 分で去ります。
 - 質問があればその時間で聞いてください。
- 回答の提出は不要です。授業後課題もありません。
- 最終試験は、07回の演習1，14回の演習2から半分出します。